

电子科技大学
UNIVERSITY OF ELECTRONIC SCIENCE AND TECHNOLOGY OF CHINA

专业学位硕士学位论文

MASTER THESIS FOR PROFESSIONAL DEGREE



论文题目 面向自动驾驶的轻量化目标检测算法研究

专业学位类别 电子信息

学 号 202222280702

作者姓名 余廷龙

指导教师 卢国明 研究员

学 院 电子科技大学（深圳）高等研究院

分类号 TP309.2 密级 公开

UDC^{注1} 004.78

学位论文

面向自动驾驶的轻量化目标检测算法研究

(题名和副题名)

余廷龙

(作者姓名)

指导教师

卢国明 研究员

电子科技大学 成都

(姓名、职称、单位名称)

申请学位级别 硕士 专业学位类别 电子信息

专业学位领域 计算机技术

提交论文日期 论文答辩日期

学位授予单位和日期 电子科技大学

答辩委员会主席

评阅人

注1: 注明《国际十进分类法 UDC》的类号。

Research on Lightweight Object Detection Algorithm for Autonomous Driving

A Master Thesis Submitted to
University of Electronic Science and Technology of China

Discipline:	Electronic Information
Student ID:	202222280702
Author:	Yu Tinglong
Supervisor:	Prof.Lu Guoming
School:	Shenzhen Institute for Advanced Study,UESTC

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得电子科技大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

作者签名：_____ 日期：____年__月__日

论文使用授权

本学位论文作者完全了解电子科技大学有关保留、使用学位论文的规定，同意学校有权保留并向国家有关部门或机构送交论文的复印件和数字文档，允许论文被查阅。本人授权电子科技大学可以将学位论文的全部或部分内容编入有关数据库进行检索及下载，可以采用影印、扫描等复制手段保存、汇编学位论文。

（涉密的学位论文须按照国家及学校相关规定管理，在解密后适用于本授权。）

作者签名：_____ 导师签名：_____

日期：____年__月__日

摘要

近年来,随着人工智能和计算机视觉技术的快速发展,自动驾驶成为学术界和工业界的重要研究方向。为了保障自动驾驶车辆的安全与高效运行,环境感知技术至关重要,其中 3D 目标检测能够为车辆提供精准的空间定位与目标识别信息。然而,现有的 3D 目标检测算法存在计算开销大、推理速度慢等问题,难以满足自动驾驶系统对实时性与可靠性的双重要求。因此,开展轻量化 3D 目标检测算法研究,提升检测效率和运行速度,已成为当前自动驾驶感知领域的关键课题。

本文围绕点云数据 3D 目标检测中的实时性和精度平衡问题开展研究,首先,对主流的基于体素编码的点云 3D 目标检测框架进行了改进,引入了更高效的柱状体编码结构,并针对点云的稀疏性特点提出进一步轻量化的方法,大幅提升了推理速度。其次,为弥补柱状体编码模型在高度信息建模方面的劣势,进一步提出基于关键特征对齐的异构知识蒸馏方法,有效提升了检测精度。两者相互协同,实现了在保证检测精度的同时,显著提升推理速度的目标。本文的主要贡献如下:

(1) 提出了一种基于柱状体编码的高效 3D 目标检测网络—FastPillarNet,并在此基础上设计了三项优化策略:在点云预处理阶段,利用 Z 轴值对地面点云进行过滤,以减少背景干扰并提升物体边界的清晰度;在点云网格编码阶段,通过按高度区间进行稀疏采样,保留关键空间信息的同时降低计算成本;在检测头部分,引入基于热图的关键特征筛选方法,仅对高置信度区域的特征进行目标回归,从而有效减少计算负担。在 KITTI 数据集上的实验结果表明,以上优化策略使 FastPillarNet 的推理速度提升了 12.44%,同时保持检测精度不变。

(2) 提出了一种基于关键特征对齐的异构知识蒸馏方法,以弥补柱状体编码模型在高度信息建模方面的不足。该方法以基于体素编码的模型作为教师模型,基于柱状体编码的模型作为学生模型,实现跨结构的知识迁移。在特征提取阶段,结合热图置信度信息提取并对齐关键特征,从而提升蒸馏效果。在 KITTI 数据集上的实验结果表明,该方法能够显著提升学生模型的检测精度,达到接近教师模型的水平。并且通过适当扩展学生模型的骨干网络,可以使其在推理速度快于教师模型 15.42% 的情况下,达到与教师模型一致的检测精度。

(3) 基于 ROS 和 RViz 设计了一个自动驾驶可视化系统,为 3D 目标检测模型的研究和应用提供直观、交互式的可视化支持。

关键词: 自动驾驶, 3D 目标检测, 轻量化, 稀疏卷积, 知识蒸馏

ABSTRACT

In recent years, with the rapid development of artificial intelligence and computer vision technologies, autonomous driving has become an important research focus in both academia and industry. To ensure the safety and efficiency of autonomous vehicles, environmental perception technology is crucial. Among these, 3D object detection can provide vehicles with precise spatial localization and target recognition information. However, existing 3D object detection algorithms often suffer from high computational overhead and slow inference speed, making it difficult to meet the dual requirements of real-time performance and reliability in autonomous driving systems. Therefore, research on lightweight 3D object detection algorithms to improve detection efficiency and operational speed has become a key issue in the field of autonomous driving perception.

This thesis conducts research around the trade-off between real-time performance and detection accuracy in 3D object detection based on point cloud data. Firstly, the mainstream voxel-based 3D object detection framework is improved by introducing a more efficient pillar-based encoding structure, and a series of lightweight optimization methods are proposed based on the sparse characteristics of point clouds, significantly improving inference speed. Secondly, to address the deficiency of pillar-based models in modeling height information, this thesis further proposes a heterogeneous knowledge distillation method based on key feature alignment, effectively enhancing detection accuracy. These two methods work collaboratively to achieve the goal of significantly improving inference speed while maintaining detection accuracy. The main contributions of this thesis are as follows:

(1) A high-efficiency 3D object detection network based on pillar encoding, named FastPillarNet, is proposed. Three optimization strategies are designed based on this framework: in the point cloud preprocessing stage, ground points are filtered based on the Z-axis values to reduce background interference and enhance object boundary clarity; in the point cloud grid encoding stage, sparse sampling by height intervals is performed to retain critical spatial information while reducing computational cost; in the detection head, a heatmap-based key feature selection method is introduced to regress objects only in high-confidence regions, effectively reducing computational overhead. Experimental results on the KITTI dataset demonstrate that these optimization strategies improve the inference

speed of FastPillarNet by 12.44% while maintaining detection accuracy.

(2) A heterogeneous knowledge distillation method based on key feature alignment is proposed to address the weakness of pillar-based models in modeling height information. In this method, a voxel-based model serves as the teacher network, while a pillar-based model acts as the student network, achieving cross-architecture knowledge transfer. During feature extraction, heatmap confidence information is utilized to extract and align key features, thereby improving the distillation effect. Experimental results on the KITTI dataset show that this method significantly enhances the detection accuracy of the student model, reaching a level close to that of the teacher model. Moreover, by appropriately expanding the backbone of the student model, it can achieve detection accuracy equivalent to the teacher model while maintaining an inference speed 15.42% faster.

(3) A visualization system for autonomous driving is designed based on ROS and RViz, providing intuitive and interactive visualization support for the research and application of 3D object detection models.

Keywords: Autonomous Driving, 3D Object Detection, Lightweight, Sparse Convolution, Knowledge Distillation

目 录

第一章 绪 论	1
1.1 研究工作的背景与意义	1
1.2 国内外研究历史与现状	3
1.2.1 基于图像的 3D 目标检测算法	3
1.2.2 基于点云的 3D 目标检测算法	4
1.2.3 基于点云图像融合的 3D 目标检测算法	7
1.3 本文的主要贡献与创新	8
1.4 本文的结构安排	9
第二章 相关理论与技术基础	11
2.1 三维目标检测的定义	11
2.2 数据集和评价指标	11
2.3 数据增强方法	15
2.4 点云数据结构化方法	16
2.5 卷积神经网络和稀疏卷积	18
2.6 经典检测头	20
2.7 非极大值抑制	22
第三章 轻量化 3D 目标检测网络-FastPillarNet	24
3.1 模型设计思路	24
3.2 地面点云过滤	26
3.3 柱状体点云按高度稀疏采样	27
3.4 骨干网络的设计	29
3.5 基于热图的关键特征提取	30
3.6 损失函数	32
3.7 实验内容与结果分析	33
3.7.1 实验环境设置	33
3.7.2 实验结果与分析	34
3.7.3 消融实验	37
3.8 本章小结	38
第四章 基于热图的关键特征对齐的异构知识蒸馏方法	39
4.1 知识蒸馏简介	39

4.2 算法思路	41
4.3 教师模型和学生模型的设计	42
4.4 朴素特征蒸馏与基于 ROI 池化的特征蒸馏实验及分析	44
4.5 基于关键特征对齐的知识蒸馏策略	46
4.6 基于关键特征对齐的知识蒸馏实验及结果分析	48
4.7 学生骨干网络扩容，进一步逼近教师模型	49
4.8 本章小结	50
第五章 基于 ROS 和 RViz 的 3D 目标检测可视化系统设计	51
5.1 ROS 系统架构及其可视化工具 RViz	51
5.2 数据准备与转换	52
5.3 图像序列和点云序列可视化	54
5.4 3D 目标检测框与 2D 目标检测框的可视化	55
5.5 车辆与目标物运动轨迹及距离可视化	57
5.6 本章小结	58
第六章 全文总结与展望	59
6.1 全文总结	59
6.2 后续工作展望	60
致 谢	62
参考文献	63

第一章 绪 论

1.1 研究工作的背景与意义

随着人工智能、传感器技术、计算硬件的飞速发展，自动驾驶技术已逐步从理论研究走向实际应用。2005 年第二届 DARPA 挑战赛，在 132 英里的莫哈维沙漠赛道上，斯坦福大学的车辆“Stanley”成功完成比赛并获胜^[1]，这是自动驾驶技术在学术和技术上的重要突破。2010 年，谷歌正式启动了自动驾驶汽车项目^[2]，谷歌的自动驾驶汽车在加州道路上成功完成了数千英里的测试，标志着自动驾驶技术从研究阶段进入实际应用阶段。2015 年，特斯拉发布了 Autopilot 系统^[3]，这是首个大规模商用的自动驾驶辅助系统。Autopilot 具备自动车道保持、自动变道和自动泊车等功能，极大地推动了自动驾驶技术在消费者市场的普及。如今，自动驾驶技术已经非常普遍，国内各大汽车厂商如比亚迪、蔚来、小鹏、理想等均已推出配备高级自动驾驶辅助系统的车型，这些系统不仅支持车道保持、自动泊车、自适应巡航等基础功能，还在逐步向更高级的 L3 甚至 L4 级别自动驾驶迈进。与此同时，百度、美团等科技公司也在积极推动自动驾驶技术的商业化落地，无人驾驶出租车和物流车已在国内多个城市试运营。自动驾驶技术正以前所未有的速度融入日常生活，成为未来交通的重要组成部分。

自动驾驶技术近年来取得的显著进展，展现出巨大的社会经济潜力。它有望大幅提高道路安全性、改善交通效率、减少交通事故，并推动智能交通系统的全面发展。据统计，约 90% 的交通事故是由人为错误引起的^[4]，而自动驾驶技术通过消除人为因素，能够显著降低事故发生率，为城市交通带来革命性变革。然而，现有的自动驾驶技术仍处于较为初级的阶段，大多数商业化应用主要集中在高级驾驶辅助系统，如车道保持、自动泊车和自适应巡航等功能，这些技术仅在良好路况的简单场景下表现稳定，要实现完全的自动驾驶仍需突破诸多技术瓶颈。其中，高效又精确的感知技术是核心挑战之一，它要求自动驾驶系统能够实时、准确地识别和理解周围环境，为后续的决策和控制提供可靠的基础。只有攻克这些关键技术，自动驾驶才能真正实现其社会经济潜力，为未来交通带来深远的影响。

自动驾驶的感知系统主要依赖于传感器（如摄像头、毫米波雷达、激光雷达等）和智能算法。通过这些传感器，自动驾驶系统能够感知交通环境中的物体，从而做出合适的决策。目标检测作为感知系统的核心任务，承担着至关重要的作用，目标检测算法的目的是从传感器数据中准确识别并定位各种目标，诸如行人、车辆、交通标志等，其检测精度和速度决定了自动驾驶系统在不同环境下的安全性

和稳定性。

在自动驾驶的目标检测系统中，精度与效率是两个互为制约的重要指标。一方面，检测精度直接关系到自动驾驶系统对目标的正确识别，精度不足可能导致误识别或漏检，进而影响驾驶安全；另一方面，检测算法的推理速度要求系统能够在毫秒级的时间内做出反应，过于复杂的模型可能导致无法满足实时性需求。因此，如何平衡精度与效率，尤其是在计算资源受限的情况下，成为了自动驾驶系统中的一大挑战。

传统的基于图像的 2D 目标检测在过去十几年中取得了显著的成就，在精度和效率上都达到了很高的水平。经典的算法如 R-CNN 系列^[5-7]、YOLO 系列^[8-10]、SSD^[11]、CenterNet^[12]等以及其后续改进版本，通过引入深度学习技术，显著提升了目标检测的性能。这些算法在公开数据集（如 COCO^[13]和 Pascal VOC^[14]）上表现优异，能够高效地检测图像中的 2D 目标，为计算机视觉领域的发展奠定了坚实基础。

然而，自动驾驶场景中的 3D 目标检测与传统图像 2D 目标检测有着本质的不同。如图 1-1 所示，图像目标检测只需要识别图像中物体的边界框和类别，自动驾驶系统则需要检测物体的中心点位置、3 维边界框、朝向角等。与 2D 目标检测相比，3D 目标检测的计算量更加复杂，因为它需要处理点云数据或多传感器融合数据，更复杂的输入信息和额外的识别维度使得 3D 目标检测在精度和效率之间的平衡变得更加困难。




图 1-1 2D 目标检测与 3D 目标检测对比

因此，在自动驾驶场景下实现轻量化 3D 目标检测显得尤为重要，自动驾驶系统计算资源有限且对精度有极高要求，需要在实时性和能耗之间做出权衡，这使得网络模型在保持高精度的同时降低复杂度成为一项极具挑战的任务，而本文则旨在针对自动驾驶场景，设计一种轻量化的 3D 目标检测算法。

1.2 国内外研究历史与现状

近年来,随着自动驾驶技术的快速发展,3D 目标检测作为感知系统的核心任务,受到了国内外研究者的广泛关注。研究者们从不同传感器和数据模态出发,开展了丰富的研究与实践。既有基于单目摄像头的 3D 目标检测,通过在深度神经网络中增加几何约束,创造性的实现了在二维图像中估计物体的深度,也有基于多目摄像头融合的方法,利用多视角信息提升了检测精度。基于点云的检测方法通过直接处理激光雷达数据,能够精确捕捉物体的三维结构,此外,点云与图像的融合方法则进一步结合了两种模态的优势,在复杂场景下表现出更强的鲁棒性。这些研究推动了 3D 目标检测技术的不断进步,为自动驾驶系统的环境感知能力提供了重要支撑。本节将简要介绍以上各类技术的发展历史和现状。

1.2.1 基于图像的 3D 目标检测算法

基于图像的 3D 目标检测算法接受单张或者多张图片作为输入,单张图片输入的方法一般通过几何约束将 2D 信息转化为 3D 空间中的边界框来实现 3D 目标检测,而多张图片输入的方法可以通过不同角度图片的视差来估计目标的深度和 3D 边界框,以实现 3D 目标检测。

Mono3D 模型^[15]首次提出了基于物体形状、路面假设和语义先验约束的单目 3D 检测方法。该方法根据目标类别先验生成 3D 候选框,将其在图像中的 2D 投影与真实 2D 边界框对齐,通过投影误差筛选出最优检测框。在此基础上, Mono3D++^[16] 和 3D-RCNN^[17] 等模型进一步引入物体轮廓信息,采用以连接线构成的固定顶点数量的网格来表示物体 3D 轮廓,通过预测网格顶点在三维空间中的位置,完成目标物体 3D 边界框的重建,从而有效提升检测的准确性和鲁棒性。Deep3DBox^[18]模型提出了一种混合离散-连续损失函数,将三维物体方向角的预测任务转化为“分类+回归”的联合形式。SMOKE 模型^[19]认为在 3D 目标检测中引入 2D 检测网络会带来冗余和噪声,因此直接基于单一关键点估计回归 3D 变量,生成 3D 边界框。该方法同时提出多步骤解耦策略,显著提升了训练收敛速度和检测精度。DID-M3D 模型^[20]提出实例深度解耦策略,将视觉深度与属性深度分离建模,并结合深度不确定性,有效提升了单目 3D 目标检测精度。MonoDTR 模型^[21]提出基于 Transformer 的端到端深度感知网络,通过辅助监督的特征增强模块提升深度特征学习,并引入深度位置编码增强深度感知能力,且无需额外计算开销。MonoDETR 模型^[22]提出基于深度感知 Transformer 的单目 3D 检测方法,融合深度图预测与深度引导解码器,提升对复杂 3D 空间结构和物体深度关系的建模能力。MonoDLE 模型^[23]提出三种策略:对齐 2D 边界框中心与 3D 物体中心、移除

远距离样本、采用 3DIoU 损失，以提高单目 3D 检测精度。MonoCon 模型^[24]利用图像中标注的 3D 边界框及其 2D 投影信号，如角点和偏移向量，通过学习辅助任务有效提升 3D 检测精度。

单目 3D 目标检测的局限性主要表现在缺乏足够的深度信息，导致推断的三维目标框容易受到遮挡、物体尺度变化等因素的影响。为了解决这一问题，学者们逐渐转向了多目 3D 目标检测方法。多目 3D 目标检测方法通过结合来自多个视角的图像信息，克服了单目图像的深度信息不足的问题，极大地提升了三维目标检测的精度。

StereoR-CNN 模型^[25]扩展了 Faster R-CNN^[7]，结合立体图像的稀疏和稠密特征，通过区域图像对齐恢复 3D 边界框，无需深度信息或 3D 位置监督，超越了当时所有全监督图像基础的 3D 检测方法。TLNet 模型^[26]提出了一种新的方法，通过使用 3D 锚点来明确地构建目标级别的对应关系，从而有效地在立体图像中的感兴趣区域之间进行匹配，并通过深度神经网络学习检测并三角化目标对象在 3D 空间中的位置。Disp R-CNN 模型^[27]通过创新的实例视差估计网络和统计形状模型，在不依赖 LiDAR 点云的情况下，能够高效且准确地从立体图像中进行 3D 目标检测。ZoomNet 模型^[28]通过自适应缩放和部位位置学习提高了立体图像中的 3D 目标检测精度，尤其在远距离和遮挡物体处理上表现优异。该模型首先使用 2D 目标检测模型获取配对边界框，然后调整边界框和相机内参，生成高质量的视差图。DSGN 模型^[29]通过引入 3D 几何体积表示，减少了图像方法与 LiDAR 方法的性能差距。它采用端到端学习同时估计深度和检测 3D 物体，实现了显著的性能提升。DSGN++ 模型^[30]对 DSGN 进行了改进，引入深度引导平面扫描和双视图立体体积方法，通过提取深度引导特征和结合前视图与顶视图特征，提升了 3D 目标检测的准确性和特征融合精度。Pseudo-LiDAR 模型^[31]通过将图像深度图转换为模拟 LiDAR 信号，突破了传统深度估计的限制，显著提升了立体图像的 3D 目标检测性能，并通过 LiDAR 检测算法实现了与 LiDAR 相媲美的精度。Pseudo-LiDAR++ 模型^[32]在 Pseudo-LiDAR 框架的基础上做出了重要的创新和改进，通过改进立体网络架构和损失函数，以及引入稀疏 LiDAR 传感器和深度传播算法，显著提高了远距离物体检测的准确性。

1.2.2 基于点云的 3D 目标检测算法

点云数据是由激光雷达（LiDAR）等传感器获取的三维空间数据集合，通常由大量的空间点构成，每个点包含了三维坐标信息（ x, y, z ）以及可能的其他信息（如反射强度、颜色等）。与图像数据相比，点云数据能提供更加直接的三维空间

信息，因此在自动驾驶、机器人等领域得到了广泛应用。点云数据的主要特点是其稀疏性和不规则性，这使得传统的图像处理方法难以直接应用于点云数据的处理，因此需要采取特殊的处理策略来进行目标检测。当前，对激光雷达点云常用的处理手段包括：投影法、体素化、点簇化以及柱状化等。

投影法将 3D 点云投影到 2D 平面上进行处理，如将点云投影为前向视场（Range View, RV）和鸟瞰图（Bird's Eye View, BEV），以便于使用 2D 卷积神经网络进行目标检测。VeloFCN 模型^[33]提出通过将激光雷达点云从前向投影到特殊格式的 2D Point-map，存储点云特征（如距离、强度等），并利用 2D 卷积神经网络进行 3D 目标检测。BirdNet 模型^[34]首次提出了基于激光雷达点云 BEV 投影的 3D 检测模型，它先将激光信息投影到鸟瞰图编码中，然后利用卷积神经网络对物体的位置信息和航向进行估计，最后通过后处理阶段计算 3D 物体的定向检测。BirdNet+ 模型^[35]提出了一个端到端的 3D 目标检测框架，基于鸟瞰图直接识别带方向的 3D 边界框。该方法使用两阶段检测器和回归分支，避免了后处理步骤，并通过更好地利用 BEV 表示中的空间信息，提升了 3D 检测性能。PIXOR 模型^[36]使用基于单阶段检测模式的点云 BEV 投影方法，进一步提升了 3D 检测的推理速度。MVF 模型^[37]提出了一种端到端的多视角融合算法，结合鸟瞰图和前向视场的优势，以提升 3D 目标检测性能，该方法通过引入动态体素化，有效解决了 BEV 中点云稀疏和密度不均的问题。LaserNet 模型^[38]基于 LiDAR 原生前向视场，采用全卷积网络预测点云的 3D 边界框分布，并通过分布融合实现高效且鲁棒的 3D 检测。

体素化是将连续点云空间划分为规则的三维网格单元（体素），并将点云映射至对应体素内，从而将稀疏点云转化为结构化数据，便于基于卷积的特征提取与检测。随后，3D CNN 通过这些体素化数据提取特征并进行建模，以完成后续的任务处理。VoxelNet 模型^[39]首次提出了基于激光雷达点云体素化的 3D 目标检测方法，并引入了体素特征编码层（VFE），通过多层堆叠将无序点云转换为结构化 3D 数据，适用于 3D CNN 进行特征提取和建模。在此基础上，SA-SSD 模型^[40]优化了体素划分过程，提出基于张量运算的体素划分策略，显著提升了计算效率。此外，考虑到 3D CNN 计算开销较高，优化 3D 卷积操作成为该领域的研究重点之一。例如，Voxel RCNN 模型^[41]在点云体素化后进行 BEV 投影，并采用 2D CNN 进行候选框回归，从而降低计算量。SECOND 模型^[42]则提出了一种基于哈希计算的 3D 稀疏卷积模块，以减少传统 3D 卷积的冗余计算，显著加速了点云体素化过程中 3D CNN 的计算效率。HVNet 模型^[43]出多尺度体素特征融合方法，通过点级融合不同尺度的 VFE 编码，并结合注意力机制和特征金字塔结构，有效提升小目标

检测性能，兼顾精度与速度。TED 模型^[44]针对 3D 稀疏卷积缺乏旋转与反转等变性的局限，提出基于特征通道共享变换的等变稀疏卷积模块，提升检测对空间变换的适应性。同时，引入等变体素池化机制，有效抑制特征冗余，提升候选框筛选效率，实现高效鲁棒的点云 3D 检测。PVT-SSD 模型^[45]提出融合点云与体素双重表征的单阶段 3D 检测方法，结合体素稀疏卷积与 Transformer 捕获长程上下文信息，并通过 Query 初始化与虚拟视图模块高效关联点与体素特征，实现高精度、高效率的点云目标检测。VoxelNeXt^[46]提出了全稀疏 3D 目标检测框架，直接基于稀疏体素特征进行预测，避免了手工设计特征或稀疏-稠密转换。其高效的稀疏卷积网络提高了检测与跟踪效率，并去除了对非极大值抑制的依赖，验证了全稀疏体素表示在激光雷达 3D 目标检测中的可行性。PV-RCNN 模型^[47]结合体素化与点簇化策略，利用体素特征编码与关键点特征融合，有效缓解池化操作带来的细节损失问题。基于此，PV-RCNN++ 模型^[48]进一步优化体素内点采样与特征聚合方式，提升检测效率与空间特征表达能力，加快推理速度。

PointNet^[49]和 PointNet++^[50]提出了基于点云点簇化处理的 3D 目标检测方法，通过多层感知机在点簇内提取特征，使得相似点更具一致性，差异点更加突出，从而有效区分点云中的物体。PointRCNN^[51]提出了基于点云点簇化的 3D 目标检测方法，利用 PointNet++ 提取点云特征并分割目标点，通过二阶段回归预测物体的 3D 边界框，第一阶段生成候选框，第二阶段进行精细优化。3DSSD^[52]提出了单阶段检测模型，省略了生成候选框步骤，直接预测 3D 目标，提升计算效率。该模型还引入了新的点云融合采样策略，优化了几何信息保留，增强了 3D 物体边界框的预测精度。IA-SSD^[53]提出了一阶式点云点簇化的 3D 检测方法，采用 PointNet++ 进行大尺度实例级下采样，减少数据规模并保留物体的语义特征，从而在保证检测精度的同时，显著提升了模型的运行效率。PointFormer^[54]模型提出了一种基于 Transformer 的点云点簇化 3D 检测方法，先对点云进行分簇，再通过基于注意力机制的 Transformer 层提取点簇内特征，替代原始 SA 层中的 MLP。模型设计了点簇内局部、点簇间全局以及局部-全局融合三种尺度的 Transformer 模块，实现多尺度特征融合，有效提升多种 3D 检测模型的性能。

点云的柱状化将稀疏的三维点云数据转化为规则的二维网格，通过将空间划分为柱状体并提取每个柱状体内的局部特征。这种方法简化了点云的表示，减少了冗余，提升了计算效率，特别适合稀疏卷积操作。柱状化在提高 3D 目标检测精度和速度方面发挥了重要作用，后续的处理可以使用 2D CNN 模型进行分析，而无需执行高计算量的 3D 卷积操作。PointPillar^[55]提出了基于激光雷达点云柱状化的 3D 目标检测方法。该模型通过对点云进行柱状化处理，利用 PointNet 提取特

征，并将柱状区域的特征进行 BEV 投影，最终使用 2D CNN 处理投影后的 BEV 特征图，避免了计算量大的 3D 卷积操作。Pillar-OD^[56] 在 PointPillars 上进行了优化，引入了前向 RV 投影与传统的 BEV 投影相结合，生成两个不同视角的特征图并将其拼接，以提升 3D 目标检测精度。该方法通过无锚点的柱状体预测，避免了锚点引起的类别不平衡问题，并简化了检测过程，同时提升了性能。SST^[57] 模型提出了一种基于 Transformer 的点云柱状化 3D 检测方法。针对基于 PointNet 的柱状区域特征提取过程中因下采样导致的小目标特征丢失问题，SST 改用 Transformer 模块对柱状区域内点云数据直接建模。由于 Transformer 的 Token 划分无需下采样，能有效保留细节特征，提升模型整体检测性能，特别是对小目标的检测效果。

1.2.3 基于点云图像融合的 3D 目标检测算法

RGB 图像和激光雷达点云在数据模态上具有不同特点，每种数据在成像过程中展现出独特的优点和局限。通过将这两种数据进行有效融合，可以发挥它们的互补优势，从而提升 3D 检测的精度。目前，RGB 图像和激光雷达点云的融合方法大致可分为三类：前期融合、中期融合和后期融合。

前期融合是指在数据输入模型之前，将 RGB 图像和激光雷达点云数据进行融合，以便在 3D 目标检测任务中利用两者的互补信息。这种方法通常通过将图像和点云对齐或投影到统一的空间中，然后将融合后的数据一起输入网络。前期融合的优势在于能够在特征提取阶段同时利用 RGB 图像的丰富纹理信息和激光雷达点云的精确空间位置，从而增强 3D 检测模型的表现。然而，这也带来了数据对齐和模态差异的挑战，特别是在处理不同尺度和视角的情况下，需要有效的配准方法来确保两种数据的准确融合。

F-PointNet 模型^[58] 提出了结合 2D 目标检测和点云前期融合的 3D 检测方法。该方法首先使用 2D 检测器在 RGB 图像中获取目标的 2D 边界框，并将其映射到点云中，筛选出与目标相关的点云数据。接着，结合点云和图像信息，构建多模态数据的 3D 视锥空间，最终通过两个 PointNet 网络分别进行点云分割和 3D 边界框回归。F-ConvNet 模型^[59] 在 F-PointNet 的基础上，对图像与点云融合后的 3D 视锥空间进行了改进。该方法通过在每个分段上独立应用 PointNet 进行特征提取，最后将各分段的特征综合，进而预测目标物体的 3D 边界框。F-PointPillar 模型^[60] 在 F-PointNet 的基础上进行了两项关键改进：首先，使用高斯分布对点云数据进行分割；其次，将基于 PointNet 的 3D 边界框回归方法替换为基于 Pillar 的回归策略。

中期融合是在 3D 目标检测中，将图像和点云分别经过初步特征提取后，在中间阶段进行融合。这种方法能结合图像的纹理信息和点云的空间关系，从而提升

目标检测精度。通过在特征层面进行融合，它能够更好地利用两种数据模态的互补性，但也需要解决特征对齐和融合的挑战。MV3D 模型^[61]提出了一个基于图像和激光雷达点云数据的 3D 目标检测方法。该方法结合激光雷达的 BEV 和 FV 投影与 RGB 图像多视角特征，通过生成候选区域并进行裁剪、对齐及池化操作，完成 3D 边界框回归。PointFusion^[62]提出了一种基于图像和点云特征融合的 3D 目标检测方法。该方法分别使用 PointNet 和 ResNet 架构提取激光雷达点云和 RGB 图像的特征，并通过一个新的融合网络将这两种模态的特征结合起来并利用 MLP 进行 3D 边界框的回归。EPNet^[63]提出了基于多尺度图像-点云特征融合的 3D 检测方法。与传统方法不同，EPNet 在每一层的特征提取网络中进行融合，从而提升了 3D 目标检测的精度。AVOD^[64]提出了基于图像-点云特征与 proposal 双层次融合的 3D 检测方法。该模型在特征层和 proposal 层进行融合，尽管增加了计算负担，但显著提升了 3D 检测性能。

后期融合将不同模态的数据独立处理，直到最后阶段才进行融合。在 3D 目标检测中，RGB 图像和点云数据分别经过独立的网络处理，最后合并结果进行决策。此方法简单灵活，有助于保持各模态的独立性。CLOCs 模型^[65]提出了一个低复杂度的图像-点云后期融合网络，通过结合 2D 和 3D 检测器生成的候选框，在 NMS 前利用几何和语义一致性来提高检测精度。Fast-CLOCs 模型^[66]在 CLOCs 基础上进行了优化，加入了轻量级的 3D-Q-2D 模块，减少了网络复杂度并提高了检测速度。

1.3 本文的主要贡献与创新

当前主流的点云 3D 目标检测方法主要分为基于点云图像融合的方法与单纯基于点云的方法两类。其中，基于图像融合的方法虽然具备较高的检测精度，但计算开销大，难以满足实时性要求；而单纯基于点云的方法中，柱状体编码方法推理速度快但检测精度不足，体素编码方法精度较高但推理速度较慢。针对上述方法在检测精度与推理效率间难以兼顾的问题，本文围绕轻量化点云 3D 目标检测展开研究，提出了一种结合两者优势、规避其缺陷的轻量化检测框架 FastPillarNet，并设计了一种基于热图的异构知识蒸馏方法，在降低计算成本的同时有效提升检测精度。主要贡献包括以下两个方面：

首先，受到基于体素编码的全稀疏卷积模型 VoxelNeXt^[46]的启发，本文对其进行轻量化改造并提出了 FastPillarNet 这一基于柱状体编码的高效的 3D 目标检测网络，并继续围绕点云预处理、点云网格编码和检测头优化三个方面进行了改进。针对 KITTI 数据集中场景大多为平地的特点，本文在点云预处理中根据 Z 轴值过

滤地面点云，减少背景点云，并使得物体之间的界限更为清晰，有效降低了计算量。在点云网格编码阶段，本文改进了经典的柱状体网格编码方法，在每个柱状体网格内按照高度区间进行稀疏采样，保留了关键的空间信息的同时又减少了后续模块的计算量。在检测头部分，基于稀疏卷积“输入特征越少，计算量越少”的特点，本文提出基于热图的关键特征筛选方法，利用热图的置信度信息筛选高质量特征，仅使用高置信度区域的特征进行目标回归，有效减少了回归任务的计算量。通过上述优化策略，FastPillarNet 在推理速度上提升了 12.44%，同时保持了检测精度。

其次，本文提出了一种基于关键特征对齐的异构知识蒸馏方法，旨在弥补基于柱状体编码的模型结构未显式建模高度信息的不足。本文认为，基于柱状体编码的模型性能较基于体素编码的模型精度较低的原因，并非编码方式导致高度信息损失，而是缺乏对高度信息的直接建模。因此，本文设计了一种异构蒸馏框架，即使用基于体素编码的模型作为教师模型，基于柱状体编码的模型作为学生模型，在特征提取阶段进行跨结构知识迁移，从而实现学生模型对高度信息的隐式建模。为了提升知识的传递效果和效率，本文提出基于热图的关键特征对齐方法，在特征对齐过程中，利用热图的置信度信息筛选关键区域，仅对齐高置信度区域的特征，以避免低质量特征对蒸馏效果的干扰。实验表明，以上方法能够有效提升 FastPillarNet 的检测精度，尤其在中等和困难样本上，在推理速度上，FastPillarNet 较教师模型提升了 18.45%，同时通过适当扩展学生模型的骨干网络，使其在推理速度仍快于教师模型 15.42% 的情况下，达到了与教师模型一致的检测精度。

1.4 本文的结构安排

本文共分为五个章节，结构安排如下：

第一章为绪论，介绍研究背景和意义，阐述 3D 目标检测在自动驾驶领域的重要性，分析现有技术的不足之处，并明确本文的研究目标与主要贡献。同时，本章还对论文的整体结构进行概述。

第二章介绍基于点云 3D 目标检测领域的基础理论与关键技术。主要包括点云数据的处理方法、稀疏卷积的基本原理、主流 3D 目标检测框架等，为后续章节的创新方法奠定理论基础。

第三章介绍本文提出的轻量化 3D 目标检测网络 FastPillarNet，包含详细的模型结构的介绍以及针对稀疏点云的三种优化思路。另外，实验结果以及分析也会在本章阐述。

第四章介绍基于关键特征对齐的异构知识蒸馏方法，将详细介绍教师模型和

学生模型的结构设计和具体的特征对齐方法，以及详细的实验设计和结果分析。

第五章介绍自动驾驶可视化系统的设计与实现，为 3D 目标检测模型的研究和应用提供直观、交互式的可视化支持。该系统能够直观展示点云数据、目标检测结果及相关信息，便于分析检测效果、调试算法。

第六章对全文进行总结并展望未来的研究方向，主要概括本文提出的轻量化 3D 目标检测方法 with 关键特征对齐的异构知识蒸馏方法的主要贡献和实验成果。同时，探讨本文研究的局限性，并对未来的研究方向进行展望。

第二章 相关理论与技术基础

本章将介绍三维目标检测领域中的相关理论和技术基础，重点讨论实现高效、精确的三维目标检测所需的基本概念与方法。首先，本章将介绍三维目标检测的定义，接着介绍点云数据的基本概念、表示方式以及在三维目标检测中的应用。为了更好地理解后续方法，本章还将对 KITTI 数据集及常用的评价指标进行简要说明。此外，本章还将探讨数据增强技术、点云数据结构化方法、卷积神经网络（CNN）及稀疏卷积的相关知识，这些都是提高三维目标检测精度和效率的关键技术。最后，本章将简要介绍经典的检测头及非极大值抑制（NMS）算法，这些方法在三维目标检测中的应用至关重要。通过对这些基础理论和技术梳理，本章为后续章节中提出的具体算法和模型提供理论支撑。

2.1 三维目标检测的定义

三维目标检测（3D Object Detection）旨在基于传感器的输入数据，对场景中的目标进行三维属性的预测。该任务通常依赖于图像或 LiDAR 传感器获取的二/三维数据，并通过检测模型进行特征提取，从而输出目标的三维信息。

一般而言，三维目标检测的核心在于估计目标的空间位置 (x, y, z) 、外观尺寸 (l, w, h) 以及旋转角度。由于传感器通常平行于地面放置，实际应用中主要关注绕垂直轴的偏航角 (θ) ，同时结合目标的类别信息 (cls) 进行综合预测。因此，第 i 个目标的三维属性可表示为：

$$B_i = [x, y, z, l, w, h, \theta, cls] \quad (2-1)$$

其中， $B = \{B_1, B_2, \dots, B_N\}$ 描述了场景中 N 个目标的三维属性集合， F_{det} 代表三维检测器， T_{sensor} 表示传感器的输入数据，即：

$$B = F_{det}(T_{sensor}) \quad (2-2)$$

在实际应用中，三维目标检测任务通常被建模为分类与回归相结合的问题。其中，分类任务用于确定目标类别，回归任务则负责估计目标的三维边界框参数。

2.2 数据集和评价指标

点云是一种由大量无序点组成的数据结构，通常由激光雷达、RGB-D 传感器等三维传感器获取。如图2-1所示，每个点通常包含三维空间坐标 (x, y, z) 以及可能

的附加信息，如颜色、法向量、反射率等。点云数据广泛用于 3D 视觉任务，包括自动驾驶、机器人感知、增强现实（AR）、虚拟现实（VR）、3D 重建等领域。




图 2-1 点云图示

点云数据的主要特点是其稀疏性和不规则性，传统的图像处理方法难以直接应用于点云数据。激光雷达产生的点云数据通常具有较高的精度和较大的覆盖范围，但在某些区域（如物体较远或反射不强的情况下），点云的稀疏性可能导致缺乏足够的点。此外，点云数据的分布是无规则的，无法像图像那样直接使用二维卷积神经网络进行处理。因此，需要采取特殊的处理策略，如降采样、体素化、聚类等方法，以有效地提取点云数据中的有用特征并进行目标检测。

KITTI 数据集由德国卡尔斯鲁厄理工学院（KIT）和丰田美国技术研究院（TTI-Chicago）联合发布，旨在推动自动驾驶、计算机视觉和机器学习领域的发展。该数据集采集于德国卡尔斯鲁厄及周边地区的城市街道、乡村道路和高速公路，涵盖了多种真实交通场景。由于其丰富的传感器配置和多任务标注，KITTI 数据集成为自动驾驶领域中最具影响力的基准数据集之一。

如图2-2所示，数据采集使用了一辆经过改装的大众帕萨特 B6，车辆配备了多种高精度传感器，如图2-3所示，包括惯性导航系统（GPS/IMU）、1 个激光扫描仪、2 个灰度摄像头、2 个彩色摄像头、4 个可变焦镜头。激光扫描仪以每秒 10 帧的速度旋转，每次旋转捕获约 10 万个点，垂直分辨率为 64 线。摄像头安装在与地面平行的位置，图像经过裁剪和校正，最终尺寸略小于原始的 1382×512 像素。摄像头的触发由激光扫描仪控制，帧率为每秒 10 帧，最大快门时间为 2 毫秒。这些传感器共同为自动驾驶任务提供了丰富且精确的多模态数据。摄像头和激光雷

达以同步方式记录数据，使得 2D 图像与 3D 点云能够精确对齐，为后续的多模态任务提供了良好基础。




图 2-2 数据采集平台





图 2-3 传感器设置

如图2-4所示，该数据集针对三维目标检测任务提供了 14999 组对应的点云和图像数据，KITTI 数据集中的 3D 目标检测任务包含了多种常见交通参与者的精确 3D 边界框标注，包括车辆、行人类和自行车。每个 3D 边界框包含位置 (x, y, z) 、尺寸（宽、高、长）以及朝向信息。此外，KITTI 还提供了 2D 边界框、物体类别和可见性信息，使得多任务学习成为可能。

KITTI 数据集作为自动驾驶领域的经典基准，定义了一套标准化的评价体系，用于全面衡量 3D 目标检测算法的性能。这些评价指标主要包括精确度（Precision）、召回率（Recall）、平均精度均值（Mean Average Precision, mAP）以及在三维空间中的定位精度，如 3D Intersection over Union（3D IoU）等。此外，还考虑了基于鸟瞰图（Bird's Eye View, BEV）的评估，以更贴合自动驾驶场景的实际需求。


 图 2-4 kitti 数据集示例^[59]

在 3D 目标检测中，三维交并比（3D IoU）是一个关键的评价指标，它衡量预测的 3D 边界框与真实框之间的空间重叠程度。3D IoU 的定义如公式2-3所示，其中， V_{pred} 和 V_{gt} 分别表示预测框和真实框的体积。

$$\text{IoU}_{3D} = \frac{V_{\text{pred}} \cap V_{\text{gt}}}{V_{\text{pred}} \cup V_{\text{gt}}} \quad (2-3)$$

较高的 3D IoU 值意味着更准确的空间定位。然而，由于三维空间中的边界框可能具有不同的朝向和高度，直接计算 3D IoU 较为复杂。因此，KITTI 数据集还引入了基于鸟瞰图的 2D IoU，即将 3D 边界框投影到地面平面上计算重叠区域，公式2-4展示了其计算方法，其中， A_{pred} 和 A_{gt} 分别为预测框和真实框在地面投影下的面积。

$$\text{IoU}_{2D} = \frac{A_{\text{pred}} \cap A_{\text{gt}}}{A_{\text{pred}} \cup A_{\text{gt}}} \quad (2-4)$$

IoU_{2D} 更加关注车辆在地面上的位置和占据空间，适用于自动驾驶场景中的路径规划和避障需求。图2-5展示了 3D IoU 和 2D IoU 的区别。




图 2-5 3D IoU 和 2D IoU 示意图

精确度和召回率是衡量检测模型性能的基础指标。精确度衡量检测出的目标中有多少是真正的正样本，而召回率则衡量所有真实目标中有多少被正确检测出来。它们的定义如公式2-5所示，其中， TP （True Positives）表示正确检测的正样本数， FP （False Positives）表示错误检测的负样本数， FN （False Negatives）表

示漏检的正样本数。在 3D 目标检测中，正确检测通常需要预测的 3D 边界框与真实框的 3D IoU 超过某个阈值（如 0.7），否则即视为错误检测。

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN} \quad (2-5)$$

平均精度（AP）是目标检测中常用的评价指标，用于衡量模型在不同置信度阈值下的检测性能。其计算基于精确度-召回率（PR）曲线，其中精确度（Precision）表示预测为正样本的目标中实际为正样本的比例，召回率（Recall）表示所有正样本中被正确检测出的比例。AP 通过计算 PR 曲线下的面积来综合评估检测效果，公式如下：

$$\text{mAP} = \int_0^1 p(r) dr \quad (2-6)$$

其中， $p(r)$ 为召回率 r 处的精确度。平均精度均值（mAP）则是所有类别 AP 的平均值，反映模型的整体检测性能。在 KITTI 数据集中，mAP 还根据目标的遮挡程度、可见度和尺寸等因素划分为不同难度，以更细致地评估检测算法的鲁棒性。

2.3 数据增强方法

数据增强是提高模型鲁棒性和泛化能力的重要手段，特别是在点云目标检测中，由于获取高质量标注数据的困难和点云数据的稀疏性，数据增强技术在实际应用中变得尤为重要。常见的点云数据增强方法包括旋转、缩放、平移等几何变换，以及通过虚拟数据生成技术扩充训练集。

（1）几何变换

常见的点云几何变换方法包括对点云进行随机旋转、平移和缩放等。这些操作通过对原始点云进行随机扰动，可以增加数据的多样性，使得模型能够适应不同的场景和观察角度。例如，点云旋转能够模拟不同视角的目标，缩放操作则可以模拟目标的大小变化。平移操作能够增强模型对物体位置变化的适应性。

（2）噪声注入

噪声注入的增强方法通过注入随机噪声来模拟现实环境中可能出现的测量误差和传感器噪声，这种方法能够让模型学习到如何处理不完美的输入数据，从而增强模型的泛化能力。常见的噪声注入方法包括高斯噪声、均匀噪声等。

（3）随机采样与数据平衡

在实际应用中，目标检测数据集可能存在样本不平衡的问题，例如某些目标类型或某些场景中的目标出现频率较低。为了解决这个问题，可以通过随机采样、

过采样或欠采样等方法来平衡数据集中的不同类别和目标数量。

(4) 真值目标采样 (GT Sampling)

这种方法的主要思想是，首先从已有数据集中提取标注好的目标对象（如车辆、行人等），然后基于点云数据的地面信息，随机生成目标的新位置和姿态，最后，将新生成的目标与原始点云数据融合，使训练数据更加丰富，增强模型的泛化能力。

2.4 点云数据结构化方法

点云数据结构化方法是将稀疏、无序的原始点云数据转化为规则、可操作的结构形式的过程。这些方法能够有效地减少点云数据的冗余信息，提高后续处理的效率，并为目标检测等任务提供更合适的输入。常见的点云数据结构化方法包括体素化、柱状化等，这些方法各自具有不同的优点和适用场景。

(1) 点云体素化

在 3D 点云数据处理中，点云体素化 (Voxelization) 是一种常用的结构化方法，其核心思想是将连续的三维空间划分为规则的体素网格，将落入同一体素内的点归为一组，从而将稀疏、不规则的点云转换为结构化的张量格式，便于使用卷积神经网络进行特征提取。

图2-6展示了一个经典的基于体素化方法的 3D 目标检测模型，首先将输入的点云数据划分为固定大小的 3D 体素网格，并将每个体素中的点集合作为输入特征，每个体素网格的点云经过 VFE (Voxel Feature Encoding) 层，如图2-7所示，对每个体素内的点进行逐点特征编码，然后通过局部聚合操作生成体素级别的表示。这些体素特征被组织成稠密的 4D 张量 (体素网格 $\times$ 特征维度)，随后通过 3D 卷积网络进行特征提取，提取后的特征通常会压缩成 BEV 特征图，最终用于 3D 边框的回归与分类。





图 2-6 基于 Voxel 的 3D 目标检测^[67]


点云体素化很好的解决了点云的无序性问题，使传统的卷积操作能够高效地应用于 3D 数据，这种网格编码方式后续通常需要配合 3D 卷积骨干网络完成检测

图 2-7 VFE Layer 示意图^[39]

任务，计算成本较高，实时性能较差，为此，后续工作 SECOND^[42] 和 PointPillars^[55] 提出了改进方法，分别通过稀疏卷积和柱状体素化提升了计算效率。

（2）点云柱状化

相比点云体素化，点云柱状化（Pillarization）是一种更高效的点云结构化方法，如图2-8所示，点云空间被划分成许多个大小一致的柱状体，每个柱状体的点会通过一个简单的特征编码过程被转换为固定长度的特征向量，这些特征向量可以组成一个 BEV 特征图，从而可以被后续 2D 卷积神经网络处理。

图 2-8 基于 Pillar 的 3D 目标检测^[67]

点云柱状化方法的一个显著优势在于其大幅度降低了计算开销。由于只在 XY 平面上进行划分，点云柱状化可以通过 2D 卷积网络来提取空间特征，极大地提高了计算效率。此外，柱状化方法还减少了 3D 体素化中稀疏特征带来的无效计算，显著提升了模型的推理速度。

2.5 卷积神经网络和稀疏卷积

卷积神经网络（Convolutional Neural Networks, CNNs）是深度学习领域中最重要模型之一，广泛应用于图像分类、目标检测、语义分割等任务中。其核心思想是利用卷积操作提取局部特征，通过堆叠多层卷积层来学习数据的多层次表示。在二维图像处理中，卷积操作可以通过公式2-7表示。

$$(I * K)(i, j) = \sum_{m=-k}^k \sum_{n=-k}^k I(i + m, j + n) \cdot K(m, n) \quad (2-7)$$

其中， I 表示输入特征图， K 是大小为 $(2k+1) \times (2k+1)$ 的卷积核， (i, j) 表示输出特征图中的位置。卷积操作通过滑动卷积核在输入特征图上逐点相乘并求和，生成输出特征图。这种操作具有局部感受野和参数共享的特点，使得模型能够有效地提取空间结构特征。在卷积层之后，通常会接入非线性激活函数（如 ReLU）以及下采样操作（如池化层），以增强网络的表达能力和抑制过拟合。图2-9很好的展示了 2D 卷积的基本流程。




图 2-9 2D 卷积操作

然而，标准卷积神经网络主要针对图像等稠密数据设计，对于 3D 点云这类稀疏数据并不高效。在 3D 点云目标检测任务中，点云数据具有高度稀疏性，大部分空间区域为空，若直接使用标准 3D 卷积处理，会产生大量无效计算，导致内存和计算资源的浪费。为了解决这一问题，稀疏卷积（Sparse Convolution^[42]）被提出，用于高效处理稀疏数据。

稀疏卷积的核心思想是仅在活跃区域（即非零特征点）上进行卷积操作，避免了对大量空区域的冗余计算，公式2-8为其计算方法，其中， $x(p)$ 和 $y(p)$ 分别表示输入和输出特征图在位置 p 处的值， $w(q)$ 是卷积核权重， $\mathcal{R}$ 表示卷积的感受野。标准稀疏卷积的一个显著特性是会在新的位置创建特征点，即只要某个位置 p 的感受野 $\mathcal{R}$ 内存在非零值输入，那么这个位置 p 也会出现在输出特征图中。因此，随着网络的层数加深，特征图的稠密度可能逐渐增加，从而提高信息传播能

力。然而，这种方式也带来了额外的计算开销，尤其是在深层网络中，稀疏特征可能迅速变得接近稠密，降低计算效率。

$$y(p) = \sum_{q \in \mathcal{R}} w(q) \cdot x(p + q) \quad (2-8)$$

如图2-10所示，标准卷积在整个输入空间上滑动卷积核，稀疏卷积仅在非零点的邻域内进行计算, 这种方法显著降低了计算量，因此适用于点云这样高度稀疏的数据。




图 2-10 稠密卷积与稀疏卷积的对比示意图

除了基础的稀疏卷积外，还有一种变体叫做子流形卷积（Submanifold Sparse Convolution），旨在解决标准稀疏卷积在深层网络中逐渐降低稀疏性的缺陷。在标准稀疏卷积中，虽然卷积仅在活跃点周围进行计算，但由于卷积核的覆盖范围可能包括空白区域，这会在原本无效的位置生成新的活跃点，导致特征图的稀疏性逐层下降，从而增加计算量和内存开销。为了解决这一问题，子流形卷积提出了一种策略：仅在原有的活跃点位置执行卷积操作，并且仅在这些位置上生成输出特征，严格保持稀疏性的恒定。其计算过程可以通过公式2-9表示。

$$y(p) = \sum_{q \in \mathcal{R}} w(q) \cdot x(p + q), \quad \text{if } p \in \mathcal{S} \quad (2-9)$$

其中， $\mathcal{S}$ 代表输入特征图的非零点索引集合。与标准稀疏卷积不同的是，SubMConv 不会在新的位置创建特征点，即如果某个位置 p 在输入特征图中未被激活，即 $p \notin \mathcal{S}$ ，那么即使它在感受野 $\mathcal{R}$ 内，它在输出特征图中也不会被计算。这样可以确保整个网络在前向传播过程中始终保持稀疏性，从而极大地减少计算开销，提高推理效率。这种特性使得子流形卷积非常适合深层网络，避免稀疏特征过早变得稠密。

在实际应用中，标准稀疏卷积适用于初期特征提取阶段，因为它能够扩大感受野并逐步增加信息密度，从而帮助网络更好地学习特征。而子流形卷积则更适合深层网络，可以在保持计算高效性的同时维持特征的稀疏性。许多 3D 目标检测网络（如 SECOND^[42]、VoxelNet^[39]）都会在浅层使用标准稀疏卷积，以增强信息传播能力，而在深层使用子流形卷积，以减少不必要的计算。通过结合这两种卷积方式，模型可以在计算效率和信息利用率之间取得良好的平衡。

2.6 经典检测头

在目标检测任务中，检测头是网络中至关重要的组件，负责将主干网络提取的特征转化为具体的检测结果，如物体的位置、类别以及其他属性。经典的目标检测头设计大致可以分为两类：基于锚框（Anchor-based）的检测头和基于关键点（Anchor-free）的检测头，每种方法都有其独特的思想和实现方式。

基于锚框的检测头是最早广泛使用的设计，代表性方法包括 Faster R-CNN^[7]和 SSD^[11]。以 Faster R-CNN 为例，其模型如图2-11所示，其检测头首先通过区域提议网络（RPN）生成一系列候选锚框，然后使用 RoI Pooling 对这些区域进行特征提取，最后通过全连接层进行分类和边界框回归。这类方法的关键在于锚框的设计，通常需要设定多个尺度和长宽比的预定义框来覆盖不同形状和大小的物体。




图 2-11 Faster R-CNN 模型架构示意图^[7]

在 Faster R-CNN 中, 边界框回归用于从候选框预测目标的精确位置。给定一个候选框 $A = (A_x, A_y, A_w, A_h)$ 和目标真实框 $G = (G_x, G_y, G_w, G_h)$, 其中 (A_x, A_y) 和 (G_x, G_y) 分别表示候选框和真实框的中心坐标, 而 (A_w, A_h) 和 (G_w, G_h) 表示它们的宽度和高度。为了让网络更容易学习边界框的偏移关系, Faster R-CNN 采用了参数化的目标偏移量定义如公式2-11所示。

$$t_x = \frac{G_x - A_x}{A_w}, \quad t_y = \frac{G_y - A_y}{A_h}, \quad t_w = \log \frac{G_w}{A_w}, \quad t_h = \log \frac{G_h}{A_h} \quad (2-10)$$

其中, t_x, t_y 代表目标框相对于候选框的归一化中心坐标偏移, 而 t_w, t_h 代表宽高的对数尺度变化。Faster R-CNN 通过边界框回归分支预测一个修正量 $(\hat{t}_x, \hat{t}_y, \hat{t}_w, \hat{t}_h)$, 并用其调整候选框的坐标, 使其更加接近目标真实框, 计算方法如公式2-11所示。

$$\hat{G}_x = A_x + \hat{t}_x A_w, \quad \hat{G}_y = A_y + \hat{t}_y A_h, \quad \hat{G}_w = A_w \cdot e^{\hat{t}_w}, \quad \hat{G}_h = A_h \cdot e^{\hat{t}_h} \quad (2-11)$$

锚框的设计复杂性以及对高效超参数调优的依赖, 促使了基于关键点的 Anchor-free 方法的出现。代表性方法如 CornerNet^[68] 和 CenterNet^[12]。这类方法摒弃了锚框的概念, 直接在特征图上预测物体的关键点或中心点。例如, CornerNet 通过检测物体的左上角和右下角来确定边界框, 而 CenterNet 则直接预测物体中心点的热力图, 并基于中心点回归物体的尺寸和其他属性。

CenterNet 是 Anchor-free 检测头中的经典之作, 其核心思想是将目标检测问题转化为关键点检测问题。图2-12展示了 CenterNet 的模型架构。其检测头首先生成一个热力图 (Heatmap) 来表示各类别物体中心点的位置, 并使用偏移量和尺寸回归来恢复完整的边界框。




图 2-12 CenterNet 模型架构示意图^[12]

对于热力图的生成, CenterNet 采用高斯分布来表示物体中心点, 热力图的每个像素点的值可以通过公式2-12计算。

$$Y_{c,p} = \exp \left(-\frac{(p_x - x_c)^2 + (p_y - y_c)^2}{2\sigma^2} \right) \quad (2-12)$$

其中 $Y_{c,p}$ 表示类别 c 在像素位置 p 处的热力值, (x_c, y_c) 为该物体的中心点坐标, σ 控制高斯分布的扩散程度。这种热力图的生成方式能够有效突出物体的中心区域, 使检测头聚焦于关键位置。

接着, CenterNet 回归中心点的偏移量和物体的尺寸。由于特征图的下采样, 热力图的分辨率通常低于原图, 因此需要通过偏移量校正中心点位置, 其回归过程可用公式2-13表示。

$$\Delta p = (x_c/s - \lfloor x_c/s \rfloor, y_c/s - \lfloor y_c/s \rfloor) \quad (2-13)$$

其中 s 为下采样因子, $\lfloor \cdot \rfloor$ 表示向下取整操作, Δp 是用来校正的偏移量。物体的尺寸回归则直接预测宽度和高度, 以重建边界框。

CenterNet 的 Anchor-free 设计简化了检测流程, 避免了繁琐的锚框超参数调整, 同时在精度和速度上取得了良好的平衡。这种基于关键点的检测头思想也被广泛应用于 3D 目标检测中, 例如 CenterPoint^[69] 将 CenterNet 的思想扩展到点云领域, 直接在鸟瞰图特征图上预测物体中心, 实现了高效且精确的 3D 目标检测。

2.7 非极大值抑制

在目标检测任务中, 由于检测网络通常会在同一个物体周围生成多个重叠的候选框, 为了去除冗余框并保留最优检测结果, 非极大值抑制 (Non-Maximum Suppression, NMS) 成为了后处理阶段的重要步骤。如图2-13所示, NMS 的核心思想是: 在多个重叠的候选框中, 仅保留置信度最高的边界框, 同时抑制其他与其重叠度较高的框, 从而减少冗余并提高检测精度。




图 2-13 非极大值抑制图示

NMS 的基本流程可以描述为: 首先, 根据每个候选框的置信度分数对所有检测框进行排序。接着, 从置信度最高的框开始, 依次计算其与其他候选框的交并比 (IoU), 并将所有与当前框的 IoU 超过设定阈值的候选框剔除。该过程不断重复, 直到候选框列表为空。其核心算法可以形式化为如下步骤:

1. 输入：一组候选框 $\mathcal{B} = \{B_1, B_2, \dots, B_N\}$ 及其对应的置信度分数 $\mathcal{S} = \{s_1, s_2, \dots, s_N\}$ ，以及 IoU 阈值 θ 。
2. 排序：按照置信度分数从高到低排序候选框。
3. 选择：选取置信度最高的框 $B_{\max}$ 并将其加入最终结果集合 $\mathcal{R}$ 。
4. 抑制：对于集合中剩余的候选框，计算它们与 $B_{\max}$ 的交并比：

$$\text{IoU}(B_{\max}, B_i) = \frac{B_{\max} \cap B_i}{B_{\max} \cup B_i}$$

如果 $\text{IoU}(B_{\max}, B_i) > \theta$ ，则剔除候选框 B_i 。

5. 重复：对剩余的候选框重复步骤 3 和步骤 4，直到所有候选框被处理完毕。
6. 输出：最终的边界框集合 $\mathcal{R}$ 。

第三章 轻量化 3D 目标检测网络-FastPillarNet

在自动驾驶系统中，检测精度和检测速度同样重要。然而，近年来为了提高 3D 目标检测的精度，越来越多的研究引入了复杂的技术，如注意力机制、Transformer 以及点云图像多模态融合等，这些方法虽然有效提升了检测精度，但却忽视了自动驾驶领域中对检测速度的高要求。因此，本章将设计一种基于纯点云数据的高效 3D 目标检测算法-FastPillarNet，在保证高精度的同时，充分考虑检测速度的优化，以满足自动驾驶系统对实时性的需求。

3.1 模型设计思路

自动驾驶技术的快速发展使得车辆在复杂的城市交通环境中能够实现自主行驶。城市道路场景具有高度复杂性，交通参与者种类繁多，如汽车、行人、骑行者等，这些目标具有不同的外观特征和运动规律。在这种环境下，目标检测算法需要能够有效识别并定位多种交通参与者。然而，由于城市交通场景的动态变化以及道路情况的不断变化，如何在保证实时性的同时提高检测精度和可靠性，成为了一项重大挑战。

传统的二维图像基于相机的目标检测方法在复杂环境中表现良好，但对于自动驾驶应用而言，图像无法提供深度信息，限制了其在三维空间中对目标的精确感知。激光雷达（LiDAR）作为一种重要的传感器，能够提供高精度的三维点云数据，极大地增强了对目标的空间感知能力。与二维图像相比，三维点云不仅增加了高度信息，还能更好地处理复杂的场景，如遮挡、远距离目标等问题。

然而，传统的点云目标检测方法通常需要将点云数据体素化后进行三维卷积，这种方法虽然能够提取空间特征，但也带来了巨大的计算开销，尤其是在车载边缘计算设备算力有限的情况下。这使得如何在保持高精度的同时，减少计算成本并提高处理速度，成为了自动驾驶中的一大难题。

VoxelNeXt^[46]作为一种全新的稀疏三维目标检测方法，提出了一种不依赖手工设计的代理（如锚点或中心点）的思路。其核心理念是在稀疏体素特征基础上，直接进行三维目标的检测，而无需将稠密特征引入到网络中。这种方法避免了稀疏到稠密转换的过程，同时使用稀疏极大值池化代替复杂的非极大值抑制（NMS），从而提高了计算效率。通过强大的稀疏卷积网络，利用稀疏体素特征进行目标检测与追踪，展现出了良好的速度-精度平衡。

尽管 VoxelNeXt 在处理稀疏点云数据方面表现出色，但为了满足自动驾驶中

车载计算系统的实时性要求和有限的计算资源，仍然需要进一步优化。为此，本章提出了一种基于点云的轻量化 3D 目标检测网络，旨在提高计算效率的同时，保持较高的检测精度。本章在 VoxelNeXt 架构的基础上，针对点云网格编码、骨干网络和检测头的优化提出了关键性的改进。

VoxelNeXt 的一大局限性在于其采用了基于体素的网格编码，这使得其骨干网络中依然使用了计算量较大的 3D 稀疏卷积。与之不同，本章提出 FastPillarNet，其模型架构图如图3-1所示，采用了柱状体编码方法，将点云转化为伪二维图像，从而能够使用计算效率更高的 2D 稀疏卷积。这一改进显著减少了计算负担，同时仍能够有效处理稀疏点云数据。




图 3-1 FastPillarNet

此外，VoxelNeXt 的检测头部分并没有充分利用稀疏卷积的优势，其使用多个独立的检测头分别预测热图、目标中心位置、边界框和目标朝向等信息，每个检测头都接收骨干网络的全部特征图作为输入。由于点云数据的稀疏性，特征图中的大部分信息实际上是背景特征，这些信息对目标检测并没有帮助，反而可能成为噪声干扰。针对这一问题，本章提出了一种基于热图的关键特征提取方法，过滤掉 80% 无关的特征，从而显著减少检测头的计算量。

3.2 地面点云过滤

为进一步提升模型的轻量化性能，本章在构建 FastPillarNet 模型的基础上，提出了一种基于点云 Z 轴值的地面点云过滤方法。该方法旨在利用点云数据的稀疏性以及自动驾驶场景中的特定特点，有效减少冗余点云数据，从而降低模型的计算复杂度。

在自动驾驶场景中，点云数据包含了大量的背景信息，其中地面点云就是其中一部分。尤其是在城市道路场景中，地面点云的平坦性和连续性使得这一部分点云并未包含有意义的目标信息。地面点云的存在不仅增加了数据量，也使得物体之间的界限变得模糊，影响目标的识别精度。因此，在数据预处理阶段过滤地面点云有助于突出目标物体，使得物体在点云中更加“显眼”，从而有助于检测任务的性能提升。如图3-2所示，经过过滤后，点云中的目标物体在空间上更加分明，背景噪声得到有效抑制，目标物体的特征更加明显。这种显著的“突出效果”从视觉上看便于人眼快速区分目标物体，从而也为目标检测算法的准确性提供了有力支持。




图 3-2 地面点云过滤前后的对比图

本章通过对 KITTI 数据集的分析，发现数据集中的大多数场景是平坦的道路或地面，即使在坡道等较为复杂的场景中，由于车辆与地面保持基本平行，地面点云的特征依然表现出一定的规律性。因此，设定一个合理的 Z 轴高度阈值来区分地面点云与非地面点云是可行的。这种方法不仅减少了输入点云的冗余量，也使得点云中的目标更加突出，从而提高了后续模型的识别效率。

设原始点云为 $P = \{p_i | p_i = (x_i, y_i, z_i), i = 1, 2, \dots, N\}$ ，其中 N 为点云中的点数， z_i 为第 i 个点的高度值。定义一个地面过滤阈值 z_{th} ，用于区分地面点云和非地面点云。地面点云过滤的过程如公式3-1表示，其中， P' 表示过滤后的点云数据集。

$$P' = \{p_i \in P \mid z_i > z_{th}\} \quad (3-1)$$

为了确保该方法的有效性，需要合理选择地面过滤阈值 z_{th} 。在 KITTI 数据集中，激光雷达安装在距离地面约 1.73 米的高度，且场景主要以平坦道路为主。因此，可以将 z_{th} 设定为略高于地面的高度，本章实验使用 $z_{th} = -1.68$ 米。这一策略能够在保留目标点云信息的同时，以极低的计算成本剔除无关的地面点。

通过地面点云过滤，不仅能够有效降低输入点云的规模，还显著减少后续 Pillar 编码和卷积计算的复杂度。此外，该方法无需引入额外的模型结构调整，即可提升推理效率，为轻量化 3D 目标检测提供更优的数据预处理策略。在自动驾驶场景中，由于车辆通常与地面保持平行，这一方法特别适用于平坦道路环境，有助于提升模型在实时检测任务中的计算效率和整体性能。

3.3 柱状体点云按高度稀疏采样

基于柱状体的网格编码是一种高效的点云特征表示方法，旨在降低点云数据的维度并提高计算效率。这一方法最早由 PointPillars^[55]提出，并在后续的 3D 目标检测任务中被广泛应用。与传统的体素编码不同，柱状体编码不再沿高度方向划分点云，而是将三维点云投影到二维平面，同时保留高度信息，从而有效减少计算开销。以 KITTI 数据集为例，在柱状体编码过程中，首先将点云空间按照固定分辨率进行划分，例如将每个柱状体的大小设定为 (0.05, 0.05, 4) 米，其中三个数分别对应柱状体的长、宽、高。这样，整个场景会被划分成许多个柱状体，每个柱状体内包含一定数量的点云数据。

在经典的柱状体编码模块中，如图3-3所示，通常会保留柱状体中的所有点云，并对其进行特征提取。每个点云首先通过多层感知机进行特征升维，映射到更高维度的特征空间。然后，对同一柱状体中的所有点云进行池化操作，如最大池化或平均池化，得到该柱状体的全局特征。这些柱状体特征最终被排列成一个伪图像，其中每个柱状体对应一个像素点的特征，供后续骨干网络进行卷积操作。




图 3-3 经典的柱状体编码网络

由于柱状体编码仅在二维平面上进行计算，因此可以使用高效的二维卷积代替三维稀疏卷积，大幅降低计算成本。同时，该方法避免了三维体素化带来的存储冗余问题，使得特征表示更加紧凑。此外，在自动驾驶场景中，点云数据通常是稀疏的，而柱状体编码能够更好地利用点云的空间结构。基于上述特点，柱状体编码已成为轻量化 3D 目标检测模型的重要组成部分，尤其适用于资源受限的实时推理任务。

毕加索的“画牛”故事是一个广为流传的艺术探索案例，它展现了如何通过简化表达保留关键信息。毕加索在他的《公牛》系列画作中，最初采用了写实的手法描绘了一头牛，随后逐步减少细节，去掉次要特征，最终仅用几笔勾勒出一幅极简主义的牛的轮廓，而这幅画依然能让观者清晰地识别出这是一头牛。这一过程表明，在表达事物时，并不需要保留所有信息，而是要提取最关键的部分，从而在降低复杂度的同时，仍然保持核心表达的完整性。

受到这一理念的启发，本章在柱状体编码中提出了一种基于高度稀疏采样的方法，以减少计算量的同时保留点云的几何结构和高度信息。在传统的柱状体编码方法中，每个柱状体内的所有点都会被输入全连接层（MLP）进行特征升维，这一操作在高密度点云中极为耗时。然而，在点云中，物体的几何信息和高度信息是最关键的，而颜色、纹理等信息并不存在，因此不必像传统图像处理那样对所有点进行等量计算。

为此，本章提出了一种按高度稀疏采样的方法，如图3-4，将一个柱状体划分为若干个更小的高度区间（即沿 Z 轴划分区域），然后在每个高度区间内随机或基于某种策略采样最多 k 个点，并仅对这些点进行特征提取。这种方法可以减少计算量，同时保留物体的整体形态信息。




图 3-4 按高度稀疏采样的柱状体编码网络

设原始点云集合为 $P = \{p_i | p_i = (x_i, y_i, z_i), i = 1, 2, \dots, N\}$ ，其中 N 为点云总

数。对于每个柱状体 B_j ，沿高度方向将其划分为 M 个高度区间，记作 B_j^m ，其中 $m \in \{1, 2, \dots, M\}$ 。在每个区间 B_j^m 中，从所有点中采样最多 k 个点，定义采样后的点集为：

$$B_j^{m'} = \{p_i \in B_j^m \mid i \in \mathcal{S}_m, |\mathcal{S}_m| \leq k\} \quad (3-2)$$

其中， $\mathcal{S}_m$ 表示在高度区间 m 内被选中的点的索引集合，最多包含 k 个元素。最终，每个柱状体的特征将由这些被选中的稀疏点提取，并经过 MLP 升维后进行池化操作，从而生成柱状体特征用于后续的检测任务。

这一方法通过减少 MLP 计算的点数，显著降低了计算成本，同时保留了点云的结构信息，使得轻量化的 3D 目标检测更加高效。

3.4 骨干网络的设计

本章借鉴了 VoxelNeXt^[46]的骨干网络设计，并对其进行了改进，以适应 2D 稀疏卷积框架，同时保留其核心特性。如图3-5 所示，本章沿用了其骨干网络的层级结构，并保持了每一层特征图的缩放比例和输出通道数。




图 3-5 骨干网络

模型中每一层的特征分别命名为 $\{F_1, F_2, F_3, F_4, F_5, F_6\}$ ，其中每一层的特征图的缩放因子依次为 $\{1, 2, 4, 8, 16, 32\}$ ，输出通道数依次为 $\{32, 64, 128, 256, 256, 256\}$ 。特征图 F_5 和 F_6 用于扩大感受野，以增强对大尺度物体的检测能力。它们与 F_4 融合后，作为网络的最终输出。融合的过程是：将 F_5 和 F_6 的特征图分别放大 2 倍和 4 倍，以便将它们的空间分辨率与 F_4 对齐，然后将 F_4 、 F_5 和 F_6 的特征合并。公式3-3展示了这一过程。其中， $UpSample(F_5, scale = 2)$ 和 $UpSample(F_6, scale = 4)$ 分别表示对 F_5 和 F_6 进行上采样，使其空间分辨率与 F_4 对齐。

$$F_{output} = F_4 + UpSample(F_5, scale = 2) + UpSample(F_6, scale = 4) \quad (3-3)$$

骨干网络每一层的具体卷积结构类似，如图 3-6 所示。除第一层外，每一层均采用一个朴素的 2D 稀疏卷积层对特征图进行 2 倍下采样，随后连接两个基于

ResNet 的稀疏基础模块 (SparseResBlock), 每个 SparseResBlock 由两个 3×3 的子流形卷积 (subMConv) 组成, 并且通过残差连接进行融合。




图 3-6 稀疏 ResNet 结构图

3.5 基于热图的关键特征提取

在 3D 目标检测任务中, 检测头负责从骨干网络提取的特征中预测物体的类别、位置、尺寸和方向等关键信息。其中, CenterPoint^[69]提出的 CenterHead 是一种经典且高效的检测头, 被广泛应用于自动驾驶场景。CenterHead 的核心思想是将 3D 目标检测任务转换为基于中心点的回归问题, 即首先预测物体中心点的热图, 然后基于该中心点进一步回归高度、尺寸、方向等参数。

具体而言, 如图3-7所示, CenterHead 接收骨干网络传入的稠密特征图, 并预测每个类别的概率热图, 标识目标中心点的位置。此外, 检测头还分别回归中心点的 2D 坐标 (x, y) 、高度值 z 、3D 边界框尺寸 (w, l, h) 以及朝向角 θ 。为了提升检测精度, CenterPoint 的检测头采用非极大值抑制进行后处理, 以消除重复检测的冗余框。




图 3-7 CenterHead 检测头

VoxelNeXt 的检测头 VoxelNeXtHead 对 CenterHead 进行了改进，其接受的输入的是稀疏特征图，而非 CenterHead 的稠密特征图，这使得计算更加高效。此外，VoxelNeXtHead 在回归过程中采用了稀疏卷积来减少冗余计算，并提升计算效率。在后处理阶段，利用最大值池化替代了传统的非极大值抑制（NMS）。这是因为自动驾驶场景中的目标通常是分散的，目标点在热图中的响应具有较高的稀疏性，因此最大值池化能够有效去除冗余检测，同时比 NMS 更高效。

本章对 VoxelNeXtHead 进行了进一步改进，针对自动驾驶场景中的点云数据稀疏性特点，提出了一种更加高效的处理方式。尽管 VoxelNeXtHead 引入了稀疏卷积，提高了计算效率，但其仍未充分发挥稀疏卷积的潜力。稀疏卷积的一个特点在于“输入越少，计算越少”，然而，VoxelNeXtHead 中的每一个回归检测头，依然接受骨干网络全部的稀疏特征作为输入。为进一步优化检测头的计算效率，本章提出了一种基于热图的关键特征提取方法，如图3-8所示，该方法利用目标类别热图来筛选高置信度区域，仅在这些区域内进行回归任务，以最大限度地减少计算冗余。




图 3-8 基于热图的关键特征筛选方法

假设检测头生成的三通道热图为：

$$H = \{H_{\text{car}}, H_{\text{pedestrian}}, H_{\text{cyclist}}\} \quad (3-4)$$

其中，每个通道 H_c 对应一种待检测目标类别（车辆、行人、自行车骑行者），

热图中的每个像素值 $H_c(x, y)$ 代表该位置为目标中心点的置信度。为了筛选出最重要的特征区域，首先确定每个类别热图中置信度最高的前 20% 位置，记作：

$$S_c = \{(x, y) \mid H_c(x, y) \geq T_c\}, \quad c \in \{\text{car}, \text{pedestrian}, \text{cyclist}\} \quad (3-5)$$

其中， T_c 是根据前 20% 置信度阈值计算得到的。接着，取所有类别的高置信度位置的并集：

$$S = S_{\text{car}} \cup S_{\text{pedestrian}} \cup S_{\text{cyclist}} \quad (3-6)$$

最终，仅保留这些位置对应的特征，作为回归任务的输入，其中 $F(x, y)$ 是原始特征图中的特征。

$$F' = \{F(x, y) \mid (x, y) \in S\} \quad (3-7)$$

这一策略大幅减少了参与计算的特征点数目，充分利用了稀疏卷积的特性，避免了在低置信度区域进行不必要的计算。同时，该方法确保了所有类别的重要检测目标都能被有效保留，保持了检测精度。

3.6 损失函数

在本研究中，检测头采用了 VoxelNeXtHead 的设计，因此损失函数部分也沿用了 VoxelNeXtHead 的多任务损失结构。该损失函数由多个子损失项组成，每个子损失项针对 3D 目标检测中的不同任务进行优化，包括热图回归、中心偏移、尺寸、朝向、z 轴中心点等预测任务。

1. 热图损失 (Heatmap Loss)

热图损失用于回归目标物体的中心点位置。在 CenterPoint 中，采用焦点损失 (Focal Loss) 来解决类别不平衡问题，确保模型关注于难以检测的样本。热图的每个像素值表示该位置为物体中心的概率。其损失形式为：

$$L_{\text{hm}} = -\frac{1}{N} \sum_{x,y,c} \begin{cases} (1 - \hat{H}_{cxy})^\alpha \log(\hat{H}_{cxy}), & H_{cxy} = 1 \\ (1 - H_{cxy})^\beta (\hat{H}_{cxy})^\alpha \log(1 - \hat{H}_{cxy}), & H_{cxy} < 1 \end{cases} \quad (3-8)$$

其中， H_{cxy} 表示真实热图的高斯分布值， $\hat{H}_{cxy}$ 为模型预测值， α 和 β 分别是超参数（本章取 $\alpha = 2$, $\beta = 4$ ）， N 为归一化因子。

2. 中心偏移损失 (Offset Loss)

由于热图经过离散化，物体中心点可能不完全对齐网格中心，因此需要回归

一个偏移量来精确定位物体中心。该损失采用 L1 损失函数：

$$L_{\text{off}} = \frac{1}{N} \sum_i \|\hat{o}_i - o_i\|_1 \quad (3-9)$$

其中， o_i 为真实偏移量， $\hat{o}_i$ 为模型预测值。

3. 尺寸损失（Size Loss）

尺寸损失用于回归 3D 边界框的长、宽、高信息，同样使用 L1 损失函数：

$$L_{\text{size}} = \frac{1}{N} \sum_i \|\hat{s}_i - s_i\|_1 \quad (3-10)$$

其中， s_i 为真实尺寸， $\hat{s}_i$ 为预测尺寸。

4. 朝向损失（Orientation Loss）

朝向损失用于回归物体的朝向信息。为了避免角度回归中的模糊性问题，CenterPoint 采用余弦正弦回归方式，将角度 θ 表示为二元向量 $(\cos \theta, \sin \theta)$ ，并使用 L1 损失进行回归：

$$L_{\text{rot}} = \frac{1}{N} \sum_i \|(\hat{r}_i - r_i)\|_1 \quad (3-11)$$

其中， $r_i = (\cos(\theta_i), \sin(\theta_i))$ 为真实方向， $\hat{r}_i$ 为预测方向。

5. Z 轴中心点损失（Height Loss）

Z 轴中心点损失用于回归 3D 物体的垂直方向中心位置，同样使用 L1 损失函数：

$$L_z = \frac{1}{N} \sum_i \|\hat{z}_i - z_i\|_1 \quad (3-12)$$

其中， z_i 为真实 z 轴中心点， $\hat{z}_i$ 为模型预测值。

6. 总损失函数

最终的损失函数是上述各个损失项的加权和：

$$L = w_{\text{hm}} L_{\text{hm}} + w_{\text{off}} L_{\text{off}} + w_{\text{size}} L_{\text{size}} + w_{\text{rot}} L_{\text{rot}} + w_z L_z \quad (3-13)$$

其中， $w_{\text{hm}}, w_{\text{off}}, w_{\text{size}}, w_{\text{rot}}, w_z$ 为各损失项的权重，本章通过模型配置参数传入。

3.7 实验内容与结果分析

3.7.1 实验环境设置

为了验证本章提出的轻量化 3D 目标检测方法的有效性，本章在特定的硬件和软件环境下进行了实验。大部分训练任务在单卡 NVIDIA RTX 3080Ti 上完

成，小部分训练任务在单卡 NVIDIA Tesla T4 上完成，所有的速度测试任务在单卡 NVIDIA Tesla T4 上完成。

实验的软件环境基于 Ubuntu 20.04 操作系统，采用 Python 3.8.19 作为开发语言，并使用 PyTorch 1.10.1 深度学习框架进行模型的构建与训练。为了提升稀疏卷积计算的效率，引入了 spconv 2.3.6 库，并依托 CUDA 11.3 进行硬件加速。此外，实验还使用了 OpenPCDet 工具箱，以便更高效地进行 3D 目标检测模型的开发与评估。

3.7.2 实验结果与分析

本章在 KITTI 数据集上进行训练和评估，划分方法采用官方推荐的方式，其中训练集包含 3712 张带有标注点云数据，用于模型训练，验证集包含 3769 张带有标注的点云数据，用于评估模型性能。点云数据以柱状体形式进行划分，柱状体的尺寸设定为 $[0.05, 0.05, 4]$ 米，每 0.1 米作为一个稀疏采样区间，每个区间最多采样 5 个点云，地面点云过滤阈值使用 $z = -1.68$ ，检测头优化方法过滤 80% 的低置信度特征。数据增强方面，实验使用了 GT Sampling 进行数据增强，同时应用随机翻转、旋转和缩放等操作，以提高模型的泛化能力。训练策略方面，优化器采用 AdamOneCycle，初始学习率设为 0.01，总训练轮数为 80 轮，批大小设为 4。学习率衰减在第 35 轮和第 45 轮时分别缩小 10 倍，并采用梯度裁剪以稳定训练过程。

为了全面衡量检测性能，本章采用了基于 KITTI 验证集的检测基准，计算了不同类别目标的平均精度 (AP)，其中召回率采用 40 个点采样。交并比 (IoU) 用于衡量预测框与真实框的重叠程度，对于体型较大的车辆目标，采用更为严格的 0.7 作为最小 IoU 阈值，而对于行人和自行车类别，由于目标尺寸较小、点云数据较为稀疏，可能仅包含数十个点，为了保证检测的稳定性和可用性，采用较为宽松的 0.5 作为最小 IoU 阈值。这样的设定有助于更合理地评估不同类别目标的检测性能。

此外，KITTI 数据集根据目标的可见性和遮挡情况，将检测难度划分为简单、中等和困难三个等级。简单类别要求目标完全可见，最小边界框高度不低于 40 像素，最大重叠比例不超过 15%；中等类别允许部分遮挡，最小边界框高度降低至 25 像素，最大重叠比例不超过 30%；困难类别则包含严重遮挡的目标，最小边界框高度仍为 25 像素，但最大重叠比例提高至 50%。这样的难度划分能够更细粒度地分析模型在不同挑战条件下的检测能力。

本章选取了多个经典的三维目标检测方法进行对比，以验证所提出方法的优势。对比方法涵盖了多种不同的检测策略，包括基于柱状体点云的 PointPillars^[55]，

基于点的方法 Point RCNN^[51]，基于体素的 CenterPoint^[69]，以及本章所参考并优化的 VoxelNeXt^[46]。

表 3-1 KITTI 验证集 3D 检测 AP_{R40} 指标对比

模型	车辆 (IOU=0.7)			行人 (IOU=0.5)			自行车 (IOU=0.5)			速度 (ms)
	简单	中等	困难	简单	中等	困难	简单	中等	困难	
PointPillars	85.41	73.97	67.76	52.02	46.40	42.48	78.72	59.95	57.24	34.5
CenterPoint	87.34	79.46	77.59	57.36	53.78	49.58	82.81	66.12	62.30	68.0
Point RCNN	88.79	79.75	77.57	64.59	57.55	50.31	89.82	72.15	67.56	147.6
VoxelNeXt	88.52	80.14	77.73	58.81	55.21	51.31	86.63	65.32	61.43	42.8
VoxelNeXt*	88.70	79.96	77.50	57.39	53.69	49.66	90.46	68.91	64.85	40.6
FastPillarNet	86.81	77.94	75.37	56.01	50.50	46.03	85.65	63.39	59.20	38.6
FastPillarNet*	86.66	77.89	75.75	57.29	52.87	48.32	85.81	63.25	59.78	33.8

VoxelNeXt* 应用了本章提出的检测头轻量化方法

FastPillarNet* 应用了本章提出的全部三种轻量化方法

表3-1 展示了各模型在 KITTI 数据集上的 3D 检测结果，包括各类别在简单、中等和困难三个难度下的 AP_{R40} 得分以及推理时间。实验结果表明，本章提出的轻量化 3D 目标检测方法在显著提升推理速度的同时，依然保持了较为可观的检测精度，展现出了良好的性能与应用潜力。

首先，从 VoxelNeXt 到 FastPillarNet* 的改造过程中，本章方法实现了一定的推理速度提升，从 VoxelNeXt 的 42.8ms 提升到 FastPillarNet* 的 33.8ms，提升率达 21.02%。原始的 VoxelNeXt 的推理时间为 42.8ms，而 FastPillarNet 将速度提升至 38.6ms，提升率达到 9.81%，另外，对 VoxelNeXt 应用了基于热图的关键特征筛选的检测头轻量化之后，优化后的 VoxelNeXt* 推理速度从 42.8ms 提升到 40.6ms，提升率达到 5.14%，并且对于车辆的检测精度基本保持不变，行人的检测精度虽稍有下降，但对自行车的检测精度却有更大的提升，总体来说保持率精度基本不变，这说明本章提出的检测头轻量化方法在提升推理速度的同时又保持了原有的检测精度。而对本章提出的 FastPillarNet 应用全部三种轻量化方法后，优化后的 FastPillarNet* 推理速度更是由 38.6ms 加速至 33.8ms，提升率达到 12.44%，并且保持识别精度基本不变，其中对车辆和自行车的识别，不同难度基本不变，而对于行人的识别还略有提升，这说明本章提出的三种优化方法，对于 FastPillarNet 的速度提升非常显著并且还保持了可观的检测精度。

其次，与现有经典方法相比，本章方法在速度与精度之间实现了良好的权衡。相较于同样采用柱状体编码并且以推理速度著称的经典模型 PointPillars，FastPillarNet*，无论在检测精度还是推理速度上都表现更优，其中对于各个类别在各种难度下的检测精度相对于 PointPillars 都实现了较大的提升，同时，

FastPillarNet* 仅需 33.8ms 的推理时间，略快于 PointPillars 的 35.5ms，充分说明本章轻量化方法在基于柱状体编码的模型上的优化能够带来精度和速度两方面的提升。

相较于 CenterPoint 和 Point RCNN 这类更复杂的 3D 目标检测模型，FastPillarNet* 虽然在精度上略有差距，但在推理速度上优势明显。虽然 CenterPoint 在车辆类别上的检测精度相对于 FastPillarNet* 有着显著的优势，但其推理时间高达 68.0ms，是本章方法的两倍以上。Point RCNN 在精度上进一步提升，尤其是在行人和自行车这类小物体上的识别精度，相较于其他模型有着大幅的提升，但其推理时间达到 147.6ms，远远无法满足实时性需求，这是因为 Point RCNN 是一种基于点云点簇化的方法，即直接对原始点云进行建模，虽然识别精度很高，但是计算量也非常大。而 FastPillarNet* 在牺牲少许精度的情况下，显著提升了推理效率，使得 3D 目标检测在自动驾驶等实时应用中更加可行。

FastPillarNet* 在速度上展现了强劲的优势，但其检测精度相较于 VoxelNeXt 以及部分高精度模型仍存在一定的差距，这表明虽然本章的轻量化方法有效减少了计算开销，但仍存在一定的精度损失。因此，在下一章节中，本章将进一步探讨一种创新的知识蒸馏方法，以弥补轻量化模型在检测精度上的不足，提升 FastPillarNet 的整体检测性能，使其在保证高效推理的同时，也能在精度上接近更复杂的基于体素编码的模型，从而进一步完善本章提出的轻量级 3D 目标检测框架。

除了 3D 检测精度外，本章还评估了各模型的 BEV 检测性能。表3-2 给出了各模型在各类别的 BEV 检测结果，同样包括三种难度的 AP_{R40} 得分及推理时间。

表 3-2 KITTI 验证集 BEV 检测 AP_{R40} 指标对比

模型	车辆 (IOU=0.7)			行人 (IOU=0.5)			自行车 (IOU=0.5)			速度 (ms)
	简单	中等	困难	简单	中等	困难	简单	中等	困难	
PointPillars	89.93	86.57	85.19	59.07	53.36	48.42	80.93	63.34	60.06	35.5
CenterPoint	91.94	88.28	86.68	63.21	59.87	55.64	90.18	72.90	68.50	68.0
Point RCNN	92.86	86.80	86.49	67.55	60.35	53.24	92.60	75.80	71.23	147.6
VoxelNeXt	91.10	87.54	86.81	63.84	60.08	56.31	90.81	70.24	65.95	42.8
VoxelNeXt*	91.86	87.91	86.98	63.17	59.72	55.75	92.72	71.87	68.05	40.6
FastPillarNet	93.37	87.83	86.88	62.81	57.54	52.93	89.65	66.89	62.46	38.6
FastPillarNet*	92.02	87.77	85.34	63.79	59.54	55.24	90.50	67.63	63.34	33.8

VoxelNeXt* 应用了本章提出的检测头轻量化方法

FastPillarNet* 应用了本章提出的全部三种轻量化方法

从表中可以看出，相比于 3D 检测结果，各模型的 BEV 检测在各个类别各种检测难度下，差别都不是很大，除了 PointPillars 的检测结果相比其他模型有较为

显著的差异，其他的几个模型检测结果虽有差异但是并不大，尤其是对于车辆类型，各个模型在三种难度下都达到了很高的检测精度，这说明在 3D 目标检测任务中，物体的分类和 2D 平面边界框的检测相对容易，如何更好的估计出物体在 z 轴的坐标值，才是实现准确的 3D 目标检测任务的关键。注意到，中等和困难难度下，实现 z 轴坐标的检测尤为困难，以车辆类型的检测为例，对于简单难度的车辆样本，BEV 检测结果和 3D 检测结果只相差 5% 以内，但是对于中等难度和困难难度的车辆样本，BEV 检测结果和 3D 检测结果相差近 10%，因此，如何提升中等难度和困难难度下的 3D 检测精度，是一个很有意义的研究方向。

3.7.3 消融实验

为了验证本章提出的三个不同轻量化方法对模型性能的具体影响，本章设计了消融实验。通过消融实验，可以清楚地看到每个方法单独使用和混合使用时对模型性能的影响，帮助本章确定哪些优化方法对提升检测精度和推理速度起到了最重要的作用，并进一步验证本章提出的轻量化优化方案的有效性。

实验模型统一使用的是本章提出的 FastPillarNet，除了应用不同的优化方法之外，所有模型在与 3.7.1 节相同的软硬件环境下以及与 3.7.2 节相同的参数设置下训练并测试速度，对于前文已训练过的两个模型，直接使用前文的结果。本章首先设计了单独采用三种优化方法的模型，其次，考虑到地面点云过滤这个方法要求地面是较为平坦的，因此本章也设计了同时使用柱状体编码按高度稀疏采样和基于概率热图关键特征筛选的检测头优化的模型，以确定这两个方法结合时的效果。

实验结果通过表3-3展示，带有 ✓ 符号表示对应的优化方法被使用，受限于纸面宽度的大小，同时为了更方便的进行结果分析，此处只展示自动驾驶领域最重要的车辆类型三种难度下的 3D 检测结果。具体优化方法包括：

优化一：使用基于 z 轴值的地面点云过滤，减少点云数量。

优化二：在柱状体编码时按高度进行稀疏采样点云。

优化三：在检测头中应用基于概率热图的关键特征筛选，以减少回归检测头的计算量。

观察实验结果可以得出，除了使用优化二的模型的精度神奇的取得了一定的提升，其余消融结果都保持了和原始模型差不多的精度，并且取得了不同程度的推理速度提升。其中，单独使用优化一的模型，速度提升最大，甚至基本与同时使用了优化二和优化三的方法提升效果一致，这是因为过滤地面点云，对整个网络都有一定影响，柱状体编码器获得的点云输入更少，其编码效率自然更高，进而又影响骨干网络和检测头的计算量。而优化二和优化三也分别得到了小幅度的

表 3-3 FastPillarNet 各优化方法消融实验 3D 检测 AP_{R40} 指标对比

优化一	优化二	优化三	车辆 (IOU=0.7)			速度 (ms)
			简单	中等	困难	
			86.81	77.94	75.37	38.6
✓			86.76	77.18	75.57	35.1
	✓		88.76	78.43	75.96	37.1
		✓	86.52	77.71	75.24	36.2
	✓	✓	86.66	77.79	75.40	34.9
✓	✓	✓	86.66	77.89	75.75	33.8

推理速度提升。另外，实验结果表明，只使用优化二和优化三的情况下，其推理速度与三种优化方法都使用的结果只相差 1.1ms，相比原始模型提升率也达到了较为可观的 9.58%，这是因为优化一与优化二和优化三的效果有所重叠，同时使用带来的提升不如三者单独使用带来的提升相加那么大。而优化二与优化三的加速效果就比较独立，两者同时使用带来的速度提升，与两者分别使用带来的提升相加基本一致。

3.8 本章小结

本章主要介绍了 FastPillarNet 模型的轻量化设计及其优化策略。通过对当前主流 3D 目标检测网络 VoxelNeXt 的优化，本章提出了针对计算效率和精度瓶颈的创新方案。具体而言，本章对模型结构进行了三方面的轻量化设计：首先，替换体素编码器为柱状体编码器，从而减少了 3D 空间的计算量；其次，骨干网络从 3D 稀疏卷积改为 2D 稀疏卷积，利用 BEV 表示实现了更高效的特征建模；最后，本章引入了三种优化策略，包括地面点云过滤、基于高度的柱状体点云稀疏采样以及检测头的关键特征筛选，进一步提升了推理速度。实验结果表明，FastPillarNet 在保证较高检测精度的同时，实现了显著的推理速度提升，相较于 VoxelNeXt，提升了 9.81% 的推理速度，三种优化策略联合使用进一步实现了 12.44% 的提速。

第四章 基于热图的关键特征对齐的异构知识蒸馏方法

第三章提出的高效 FastPillarNet 模型通过三种轻量化策略显著提升了推理速度，提供了一种高效的 3D 目标检测解决方案，为自动驾驶应用提供了有效的支持。然而，由于 FastPillarNet 基于柱状体编码，相较于基于体素编码的模型，其在高度维度上的显式建模能力较弱，导致该模型在检测精度上相较于一些先进的基于体素编码的网络存在一定的劣势。针对这一问题，本章提出了一种创新的基于关键特征对齐的异构蒸馏网络，旨在弥补柱状体编码模型在高度信息建模上的不足，进一步提升检测精度。

4.1 知识蒸馏简介

知识蒸馏（Knowledge Distillation, KD）是一种模型压缩技术，旨在将大型、复杂的教师模型中的知识迁移到较小的学生模型中，从而在降低模型复杂度的同时保持较高的性能。这一概念最早由 Hinton 等人^[70]在 2015 年提出，如图4-1所示，其核心思想是利用教师模型的输出作为软标签，引导学生模型进行训练。本章在此处介绍最经典的标签蒸馏和 Logit 蒸馏。




图 4-1 经典的知识蒸馏结构图^[71]

标签蒸馏是知识蒸馏的基础形式，其核心在于利用教师模型生成的软标签作为学生模型的学习目标。这些软标签不仅包含了正确类别的信息，还反映了不同类别之间的相似性。公式4-1给出了获得软标签的方法，其中， z_t 是教师模型的输出 Logit 向量，通过 Softmax 函数和温度参数 T 得到软标签， $p_t^{(i)}$ 表示第 i 个类别的概率，温度参数 T 控制分布的平滑程度，较大的 T 值会产生更平滑的概率分布。

$$p_t^{(i)} = \frac{\exp(z_t^{(i)}/T)}{\sum_j \exp(z_t^{(j)}/T)} \quad (4-1)$$

公式 4-2 定义了 Kullback-Leibler (KL) 散度，它用于衡量教师模型输出的软目

标概率分布 p_t 与学生模型输出的软目标概率分布 p_s 之间的差异。学生模型的输出通过同样的方法计算后，通过公式4-3所计算蒸馏损失，由于 softmax 计算中的温度 T 会影响梯度的缩放，因此额外乘以 T^2 以补偿梯度缩放的影响，确保训练的稳定性。

$$\text{KL}(p_t \parallel p_s) = \sum p_t \log \frac{p_t}{p_s} \quad (4-2)$$

$$\mathcal{L}_{\text{KD}} = T^2 \cdot \text{KL}(p_t \parallel p_s) \quad (4-3)$$

公式4-4展示了最终的训练损失，通常是蒸馏损失和学生模型的交叉熵损失的加权和，其中 α 为权重超参数。标签蒸馏通过软标签传递更多类别间的关系信息，有助于学生模型获得更好的泛化能力。

$$\mathcal{L} = \alpha \cdot \mathcal{L}_{\text{CE}} + (1 - \alpha) \cdot \mathcal{L}_{\text{KD}} \quad (4-4)$$

Logit 蒸馏直接利用教师模型和学生模型的 Logit 输出进行匹配，而非依赖 Softmax 后的概率分布，其架构如图4-2所示。




图 4-2 Logit 蒸馏架构图^[71]

Logit 蒸馏认为，直接对齐教师和学生的 Logit 输出能够传递更丰富的细节信息，尤其在分类边界附近的样本。如公式4-5所示，其损失函数通常采用均方误差（MSE）来衡量两者的差异，其中 $z_t^{(i)}$ 和 $z_s^{(i)}$ 分别为教师和学生模型的第 i 个样本的 Logit 输出， N 为样本总数。Logit 蒸馏相比标签蒸馏更注重模型的输出细节，尤其适用于对输出分布敏感的任务。

$$\mathcal{L}_{\text{Logit}} = \frac{1}{N} \sum_{i=1}^N \|z_t^{(i)} - z_s^{(i)}\|^2 \quad (4-5)$$

4.2 算法思路

在现有的点云 3D 目标检测方法中，基于体素和基于柱状体的网络各具优势，形成了不同的技术路线。基于体素的方法通过将点云划分为固定大小的三维体素单元，并利用 3D 卷积在三维空间中显式建模，这种方式可以有效捕捉物体的几何信息，例如形状和高度，使得模型在 3D 空间中的目标识别能力更强。然而，3D 卷积的计算复杂度较高，导致推理速度较慢，难以满足对实时性要求较高的应用场景，如自动驾驶。相较之下，基于柱状体的方法通过将点云在水平方向上划分为柱状单元，并采用 2D 卷积进行特征提取，这种策略大幅减少了计算量，提高了模型的推理速度，使其在实时应用中更具竞争力。然而，由于该方法在高度维度上的信息被压缩，导致其对物体几何结构的建模能力相对较弱，尤其是在高度信息的感知方面存在一定的不足。这种不足可能导致 3D 检测精度下降，限制了模型在复杂场景下的表现。

通过上一章对 3D 检测结果和 BEV 检测结果的分析，可以发现，各模型在 BEV 任务中的检测性能在各个类别和难度级别下差异相对较小，除了 PointPillars 由于结构上的原因表现较弱外，其余模型的 BEV 结果总体较为接近，尤其是车辆类别，在所有难度级别下都达到了较高的检测精度。这一现象表明，在 3D 目标检测任务中，物体的分类和 2D 平面上的边界框检测相对容易，而如何准确预测物体在 z 轴上的坐标才是实现高精度 3D 目标检测的关键挑战。进一步分析中等和困难难度下的 3D 检测结果可以发现，对于简单难度的车辆检测，BEV 结果与 3D 结果的精度差距通常在 5% 以内，而在中等和困难难度下，这一差距增大至近 10%。这表明在复杂场景下，估计目标的高度信息变得更加困难，因此提升中等和困难难度下的 3D 检测精度，是一个值得深入研究的重要方向。

基于这一观察，本章提出了一种新的思路：尽管基于柱状体的网络在编码阶段完整保留了点云中每个点的坐标信息，但由于特征提取方式的限制，其对物体高度信息的学习能力较弱。然而，基于体素的网络能够更好地捕捉物体的三维几何信息，因此是否可以利用基于体素的网络作为教师模型，以蒸馏的方式将其丰富的几何信息传递给基于柱状体的学生模型，从而在保持高推理效率的同时提升 3D 检测精度？

为此，本章提出了一种新颖的异构特征蒸馏网络，以解决这一问题。该方法的核心思想是利用基于体素的教师模型的强大几何建模能力，引导基于柱状体的学生模型学习更精细的 3D 结构信息，从而弥补其在高度信息建模上的不足。具体而言，本章设计了一种特征对齐机制，使得异构的教师模型（基于体素编码）和学生模型（基于柱状体编码）在特征层面建立联系。通过选择两者在空间语义上对

应的特征层，并使用特征蒸馏损失函数强制学生模型的特征向教师模型靠近，使其学习教师模型的空间结构表达能力。这种方式不仅能够帮助学生模型更有效地理解物体的三维几何信息，尤其是高度信息，还能在不显著增加计算开销的情况下提升其 3D 检测能力。

与传统的蒸馏方法不同，本章提出的异构特征蒸馏方法关注的是特征表示形式差异较大的网络之间的知识传递问题。由于体素网络和柱状体网络的编码方式不同，它们的特征表示在空间分布、信息密度等方面存在较大差异，因此如何实现有效的特征对齐成为本研究的关键挑战。本章的解决方案为基于柱状体的网络提供了一种新的优化思路，使其能够继承体素网络的几何建模优势，同时保持自身的计算效率，为高效高精度的 3D 目标检测提供了一种可行的解决方案。

4.3 教师模型和学生模型的设计

如图4-3所示，教师模型采用了 VoxelNeXt 作为基础架构，整体结构包括体素编码模块、3D 骨干网络、高度压缩模块以及检测头部分。其中，体素编码模块的主要作用是将稀疏的点云数据转换为规则化的体素表示，以便后续神经网络处理。具体而言，首先将输入点云划分为固定大小的体素单元，每个体素的空间尺寸设定为 $[0.05, 0.05, 0.1]$ 米，使得点云能够被映射到规则化的体素空间。在每个体素内，最多采样 5 个点用于特征提取，以保留局部空间信息，同时减少计算量。




图 4-3 教师模型和学生模型

在体素特征编码（Voxel Feature Encoding, VFE）过程中，本模型采用了 MeanVFE 编码方法。MeanVFE 的核心思想是通过计算体素内点云的均值特征，从而提取稳定的局部表示。设一个体素 v 内包含 N_v 个点，每个点的特征向量表示为 $p_i \in \mathbb{R}^d$ ，其中 d 表示点的原始特征维度（例如坐标、高度、强度等）。MeanVFE

计算该体素的平均特征的过程如公式4-6所示。其中, $f_v \in \mathbb{R}^d$ 代表体素的最终特征。这种方法能够有效减少点云数据的稀疏性影响, 并通过均值特征提供稳定的局部表示。此外, 由于所有体素的特征维度固定, 使得后续 3D 骨干网络能够高效处理规则化的输入数据。

$$f_v = \frac{1}{N_v} \sum_{i=1}^{N_v} p_i \quad (4-6)$$

教师模型 3D 骨干网络保持与第三章介绍的 FastPillarNet 相似的架构, 只是将 2D 稀疏卷积换成了 3D 稀疏卷积。该骨干网络由六个阶段 (stages) 组成, 每个阶段的特征分别记作 $\{F_1, F_2, F_3, F_4, F_5, F_6\}$ 。其中, 各阶段特征图的空间缩放因子依次为 $\{1, 2, 4, 8, 16, 32\}$, 对应的输出通道数分别设定为 $\{32, 64, 128, 256, 256, 256\}$, 以确保特征在逐层提取的过程中具备足够的表达能力, 同时控制计算开销。

为了提升网络的感受野并增强特征表达能力, 教师模型的骨干网络的高层特征中引入了特征融合机制, 重点针对 F_4 、 F_5 和 F_6 进行处理。具体而言, 由于 F_5 和 F_6 具有更大的感受野, 但空间分辨率较低, 因此需要对其进行上采样, 使它们的空间尺度与 F_4 保持一致。其中, F_5 经过 2 倍的上采样, F_6 经过 4 倍的上采样, 从而在空间尺度上对齐至 F_4 的分辨率。随后, 将三者的特征进行通道维度上的拼接, 并通过共享的稀疏卷积进行特征变换, 以进一步融合不同尺度的语义信息。这种融合策略能够在保持 3D 结构信息的同时, 提升网络对不同尺度目标的检测能力。完成特征融合后, 所得特征仍然保持 3D 形式, 并进一步输入至高度压缩模块。高度压缩过程是完全稀疏的, 其核心思想是将所有体素投影到地面, 并对相同位置的特征进行求和。

教师网络的检测头原始 VoxelNeXtHead 方案不同, 本章在教师模型中引入了与学生模型一致的基于热图的关键特征筛选方法, 以确保蒸馏过程中教师模型与学生模型的检测头保持统一。这种设计的主要目的是消除由于检测头结构差异而引入的性能偏差, 从而能够更准确地验证学生模型是否真正学习到了教师模型的高层特征表达能力, 而非仅因检测头的不同而获得性能提升。

学生模型沿用了 FastPillarNet 的完整结构, 其柱状编码器与检测头均采用相同的轻量化策略, 以在确保检测精度的同时, 进一步降低计算复杂度和推理延迟。由于教师模型与学生模型在整体网络架构上的高度相似性, 二者在蒸馏过程中能够实现高效的特征对齐和信息传递, 从而使得学生模型可以充分学习教师模型的特征表达能力, 并继承其对物体几何结构和高度信息的建模能力。

4.4 朴素特征蒸馏与基于 ROI 池化的特征蒸馏实验及分析

为了验证基于柱状体网络能够从基于体素网络中学习物体几何信息及高度特征,本章首先在 KITTI 数据集上训练了 VoxelNeXt 作为教师模型,并将 FastPillarNet 作为学生模型进行蒸馏训练。为了有效地将教师模型的知识传递给学生模型,本章首先尝试了朴素特征蒸馏和 ROI 特征蒸馏两种方法,旨在优化学生模型的特征学习能力,使其在轻量化的同时仍能保持较高的检测精度。

朴素特征蒸馏是一种最基本的特征蒸馏方法,其思想是直接对齐教师模型和学生模型的中间特征表示,并通过最小化二者之间的误差来优化学生模型的学习过程。实验中,本章选择对齐教师模型和学生模型在检测头输入阶段的特征,即学生模型骨干网络输出的稀疏二维特征图和教师模型骨干网络输出后经过高度压缩后的稀疏二维特征图,保证二者在形状和通道数上保持一致。在此基础上,本章采用均方误差作为蒸馏损失,公式4-7展示了计算过程。其中, $F_s(i)$ 和 $F_t(i)$ 分别表示学生模型和教师模型在第 i 个特征点上的特征值, N 是特征点的总数。

$$\mathcal{L}_{\text{feat}} = \frac{1}{N} \sum_{i=1}^N \|F_s(i) - F_t(i)\|^2 \quad (4-7)$$

ROI (Region of Interest) 特征蒸馏受到 Faster R-CNN^[7]提出的 ROI 机制的启发,主要思想是在进行特征对齐时,仅对目标物体所在的 ROI 区域进行特征蒸馏,而非全局特征对齐。这样可以让学生模型更关注物体本身的关键特征,而减少背景区域对蒸馏过程的干扰,从而提升蒸馏效率。本章的方法流程如下:

1. 获取 ROI 区域: 首先,基于教师模型和学生模型的检测结果,分别获取两者预测的 ROI 区域(即物体的候选框),这些区域是模型认为可能包含目标物体的部分。

2. ROI 区域匹配: 由于教师模型和学生模型的检测结果可能不完全一致,本章采用 IoU (Intersection over Union) 匹配策略,确保教师模型和学生模型的 ROI 之间能一一对应。具体而言,对于每个学生模型的 ROI,寻找 IoU 最高且大于设定阈值的教师模型 ROI 进行匹配。

3. ROI 特征提取: 由于教师模型和学生模型的特征图分辨率可能不同,本章使用 ROI 池化 (ROI Pooling) 操作,将不同大小的 ROI 特征调整到相同的固定尺寸,以便后续计算损失。

4. 计算 ROI 特征蒸馏损失: 最终,本章对教师模型和学生模型对应的 ROI 特征进行均方误差计算,以最小化二者的特征差异,损失函数如公式4-8所示。其中, R_j 表示第 j 个 ROI 区域, $\Phi_s(R_j)$ 和 $\Phi_t(R_j)$ 分别表示学生模型和教师模型在

该 ROI 区域提取的特征， M 为 ROI 数量。

$$\mathcal{L}_{\text{roi}} = \frac{1}{M} \sum_{j=1}^M \|\Phi_s(R_j) - \Phi_t(R_j)\|^2 \quad (4-8)$$

对于以上两个蒸馏方法，本章使用与 3.7.1 节相同的软硬件环境和 3.7.2 节基本一致的设置在 KITTI 数据集上进行实验。与 3.7.2 节不同的是，此处实验优化器采用 AdamOneCycle，初始学习率设为 0.003，并结合 OneCycle 机制进行动态调整，以确保训练的稳定性与高效性。此外，权重衰减设为 0.01，以减少过拟合现象，而梯度裁剪则被设置为 10，以防止梯度爆炸。动量参数在训练过程中从 0.95 逐步衰减至 0.85，以适应不同阶段的优化需求。实验结果如表4-1所示，其中车辆、行人、自行车的 IOU 分别取 0.7、0.5、0.5。

表 4-1 KITTI 验证集特征蒸馏 3D 检测 AP_{R40} 指标对比

模型	车辆 (IOU=0.7)			行人 (IOU=0.5)			自行车 (IOU=0.5)		
	简单	中等	困难	简单	中等	困难	简单	中等	困难
VoxelNeXt	88.70	79.96	77.50	57.39	53.69	49.66	90.46	68.91	64.85
FastPillarNet	86.66	77.79	75.40	55.55	52.43	48.73	91.37	68.14	63.87
FastPillarNet ¹	87.87	77.78	75.49	52.92	49.96	46.15	87.24	65.32	61.19
FastPillarNet ²	87.81	78.54	76.25	57.68	53.07	48.57	85.74	64.22	60.76

FastPillarNet¹ 使用了朴素特征蒸馏

FastPillarNet² 使用了 ROI 特征蒸馏

从实验结果可以看出，经过朴素的特征蒸馏后的模型 FastPillarNet¹ 效果并不理想，相较于未经蒸馏的学生模型，部分类别和难度的检测精度甚至出现了下降，可能的原因是直接对齐整体特征可能会引入不必要的信息干扰，影响模型的学习。相比之下，经过 ROI 特征蒸馏后的 FastPillarNet² 模型在车辆和行人类别的中等和困难样本上取得了一定提升，自行车的检测精度却反而下降了，说明仅对目标区域的特征进行对齐是更有效的策略，但是提升效果比较有限且有较大的局限性。因此，本章进一步探索更合适的蒸馏方法，以更有效地提升 FastPillarNet 的检测能力，同时保持其计算效率。

经分析，本章发现点云数据的稀疏性及其高比例的背景信息对蒸馏过程产生了显著影响。点云数据通常包含大量无关的背景信息，而在生成特征图时，这些背景信息仍然占据主导地位，导致特征图中的大部分内容并非直接与目标物体相关，而是大量的背景或空白区域。这种特性使得特征蒸馏过程面临额外的挑战，尤其是在传统的朴素特征蒸馏方法下。

朴素的特征蒸馏方法通常采取全局对齐的方式，即在所有空间位置上强制使学生模型的特征图与教师模型的特征图保持一致。然而，由于背景信息在特征图

中占据了较大比例，学生模型在对齐过程中不仅会关注到目标物体的特征，还会被迫对齐教师模型的背景特征。这种情况导致了一种资源分配不均的现象，即在特征对齐过程中，学生模型的大量计算资源和梯度更新被浪费在背景区域，而真正关键的目标特征却未能获得足够的关注。特别是在稀疏点云场景下，目标物体的特征本身已经较为稀疏，这种均匀对齐的策略进一步削弱了关键特征对齐的有效性，从而影响了蒸馏效果的提升。

在朴素特征蒸馏中，由于所有位置的重要性被视为相同，导致大部分的梯度更新都发生在背景区域，而作用于关键目标区域的参数更新相对较少。这种情况不仅降低了蒸馏的效率，还可能导致学生模型学习到错误的特征分布，使得检测性能难以提升。因此，在稀疏点云数据上，朴素特征蒸馏方法的有效性受到显著限制，难以有效地传递教师模型关于目标物体的关键信息。

针对上述问题，本章尝试引入基于 ROI 池化的特征蒸馏方法，以减少背景信息对蒸馏过程的干扰。ROI 池化是一种常用于目标检测任务的特征处理技术，其核心思想是在特征图中仅关注候选区域的特征，并对这些特征进行池化处理，使得后续的计算更加集中于目标区域。在蒸馏过程中，ROI 池化可以有效地筛选出可能包含目标物体的区域，从而减少背景区域的影响，使得特征对齐更加专注于目标物体的关键信息。

相比于朴素特征蒸馏方法，基于 ROI 池化的蒸馏方法能够在一定程度上提升对目标区域的关注度。然而，由于 ROI 池化本身存在一些固有的局限性，例如在池化过程中可能引入量化误差、特征分辨率降低、以及在处理不同尺度目标时不够精细等问题，导致其蒸馏效果仍然不够理想。此外，对于点云数据来说，目标物体的形态通常较为复杂，固定大小的 ROI 可能无法精准覆盖所有关键信息，这进一步限制了基于 ROI 池化的蒸馏方法在点云数据上的适用性。

不过，基于 ROI 池化的蒸馏方法相较于朴素蒸馏的提升也为本章提供了重要的启发——对特征图中关键区域的对齐是有效的。因此，本章可以在此方向上进一步研究，探索更加精细的对齐策略，以充分利用目标区域的特征信息，同时降低背景噪声对蒸馏效果的干扰。

4.5 基于关键特征对齐的知识蒸馏策略

本文第三章针对检测头进行了改进，提出了一种基于热图提取关键特征的策略，旨在在不降低精度的情况下，提高模型的推理速度。实验结果表明，即使本文的方法过滤掉了 80% 的特征，仍然能够保持原有的检测精度，这说明保留下来的特征确实是对目标物体识别至关重要的关键特征。因此，在进行基于特征的知识蒸馏时，应优先保留这些关键特征，以提高蒸馏效率。

识蒸馏时，本章继续沿用这一策略，通过筛选出最为关键的特征进行蒸馏，以避免背景特征的干扰，从而提升蒸馏的效率和效果。

图4-4 直观地展示了这一思路。在该图中，教师模型的特征图位于上方，学生模型的特征图位于下方。其中，蓝色色块表示高置信度的前景特征，而黄色色块表示背景特征。可以看到，在背景区域中，某些位置的背景特征在教师模型的特征图中存在，而在学生模型的特征图中可能缺失，或者反之。如果直接使用朴素的特征对齐策略，由于背景特征的对齐带来的较大损失值，学生模型可能会被迫学习无关的背景信息，甚至将背景特征误认为是重要的学习目标，从而影响蒸馏过程的效果。为了解决这一问题，本章提出了一种基于热图的关键特征对齐策略。在进行特征对齐之前，首先利用热图筛选出与目标检测最相关的关键特征，并去除背景特征的影响。这样一来，学生模型在对齐特征时，不再需要对齐背景信息，而是将注意力集中在前景区域。即使某些位置的教师模型特征图中包含关键特征，而学生模型特征图中暂时缺失，这种情况正是学生模型需要学习的目标区域。因此，本章的方法能够有效地引导学生模型学习物体相关的关键信息，而不会受到背景信息的干扰。




图 4-4 基于关键特征对齐的知识蒸馏

与朴素特征蒸馏相比，基于热图的关键特征对齐策略提供了一种更加高效且精确的知识蒸馏方法。它不仅避免了背景特征对蒸馏效果的干扰，还能够确保学生模型能够专注于物体相关的关键特征，从而显著提高蒸馏效率。该方法有望在

提高特征蒸馏质量的同时，还能够进一步提升模型的训练效率，使得学生模型能够更加精准地学习教师模型中的有用信息。

4.6 基于关键特征对齐的知识蒸馏实验及结果分析

本章在前面训练好的教师模型 VoxelNeXt 和学生模型 FastPillarNet 的基础上，设计了新的蒸馏实验，以验证本章提出的基于热图筛选的特征蒸馏策略的有效性。本章利用检测头的热图信息筛选出关键区域特征后再进行对齐，以避免背景噪声的干扰，提高蒸馏效率。公式 4-9 展示了这种方法对应的损失函数，其中， $H(x)$ 为热图掩码，仅对关键特征区域进行对齐， N 为所有特征点的总数。该损失函数确保学生模型的学习重点集中在对目标检测有贡献的特征区域，而不受无关背景信息的干扰。

$$\mathcal{L}_{\text{hm}} = \frac{1}{N} \sum_{i=1}^N H(x_i) \cdot \|(F_s(x_i) - F_t(x_i))\|_2^2 \quad (4-9)$$

使用新的蒸馏方式，本章在 KITTI 数据集上重新训练了 80 轮，实验环境与 4.5 节保持一致，实验结果如表 4-2 所示，其中车辆、行人、自行车的 IOU 分别取 0.7、0.5、0.5。

表 4-2 KITTI 验证集关键特征对齐蒸馏 3D 检测 AP_{R40} 指标对比

模型	车辆 (IOU=0.7)			行人 (IOU=0.5)			自行车 (IOU=0.5)		
	简单	中等	困难	简单	中等	困难	简单	中等	困难
VoxelNeXt	88.70	79.96	77.50	57.39	53.69	49.66	90.46	68.91	64.85
FastPillarNet	86.66	77.79	75.40	55.55	52.43	48.73	91.37	68.14	63.87
FastPillarNet ¹	87.87	77.78	75.49	52.92	49.96	46.15	87.24	65.32	61.19
FastPillarNet ²	87.81	78.54	76.25	57.68	53.07	48.57	85.74	64.22	60.76
FastPillarNet ³	88.14	79.22	77.26	58.57	53.88	49.91	86.60	68.33	65.71

VoxelNeXt 为教师模型，推理时间为 42.8ms

FastPillarNet 为学生模型，推理时间为 34.9ms

FastPillarNet¹ 使用了朴素特征蒸馏

FastPillarNet² 使用了 ROI 特征蒸馏

FastPillarNet³ 使用了本章提出的关键特征对齐知识蒸馏

实验结果表明，相较于未进行蒸馏的 FastPillarNet，本章提出的基于关键特征对齐的知识蒸馏方法蒸馏后的 FastPillarNet³ 模型，在各类别和不同难度等级的检测精度上均取得了更显著的提升，尤其是在行人类别的中等和困难样本，以及自行车类别的困难样本上，均达到了接近甚至超越教师模型 VoxelNeXt 的水平，并且推理速度优于教师模型，提速率达到 18.45%。这表明，相较于朴素特征蒸馏和 ROI 特征蒸馏，仅对关键区域的稀疏特征进行对齐能够更有效地传递教师模型的知识，同时避免无关信息的干扰。其优势可能来自以下几点：首先，关键区域对

齐能够更加精准地关注目标物体的关键信息，而非整个特征图的强制匹配，从而减少背景噪声对学生模型学习的影响；其次，该方法结合了模型自身的检测结果进行指导，使得蒸馏过程更加符合学生模型的学习特点，提高了特征迁移的有效性。尽管该方法在大多数情况下表现优越，但仍然存在优化空间，例如如何进一步提升难例的学习能力，将是后续研究的方向。

4.7 学生骨干网络扩容，进一步逼近教师模型

本章通过基于关键特征对齐的知识蒸馏，使学生模型的识别精度大幅提升，接近教师模型的性能。这一结果表明，基于柱状体编码结构的网络确实具备从基于体素编码结构的网络学习几何形状和高度信息的潜力。尽管柱状体编码方式相比体素编码在建模能力上有所削弱，但通过合理的知识蒸馏策略，学生模型依然能够有效地学习教师模型的高层特征表示，并在目标检测任务中取得显著的精度提升。然而，正如本章开头所讨论的，本章认为学生模型在理论上完全有能力学习到这些知识，但目前的实验仅仅展示了精度的提升，并未充分验证其学习能力的极限。因此，本节将进一步增强学生模型，使其达到与教师模型一致的检测精度。

PillarNeSt 模型^[72]提出了一种扩展基于柱状体结构的骨干网络的方法，并表明适当增加模型容量有助于柱状体结构的网络学习到与体素结构网络相似的特征表达。受到该研究的启发，本章在实验设计上也尝试探索学生模型在不同架构复杂度下的表现。本章在设计学生模型时，优先考虑了与教师模型结构上的一致性，以确保蒸馏过程中知识传递的有效性。因此，在骨干网络的设计上，本章采用了相同的卷积阶段数量，并在每个阶段保持相同的卷积层数。然而，由于学生模型在特征提取过程中，将 3D 卷积简化为 2D 卷积，这一转换虽然提升了计算效率，但同时也显著减少了模型的参数量和特征建模能力，可能影响模型在高度信息和局部几何结构上的学习效果。

为了进一步验证学生模型的潜力，并探讨其在适当扩展后的表现，本章尝试增加其骨干网络的复杂度，以提升特征提取能力的同时仍然保持较低的计算开销。在保持整体架构不变的前提下，本章对 ResNet 基础卷积模块的数量进行了调整，将每个阶段的基础卷积模块数量从 2 增加到 3，从而增强学生模型的特征建模能力，并弥补因 3D 卷积转换为 2D 卷积所带来的信息损失。随后，本章重新训练了这一增强版的学生模型，并继续采用基于热图的关键特征对齐蒸馏方法，以确保学生模型能够更加有效地学习教师模型的高层特征信息。通过这一实验设置，本章期望能够观察到学生模型在更强特征提取能力下的性能变化，并进一步评估其学习能力的上限，以为未来基于柱状体编码结构的轻量级 3D 目标检测网络设计提

供新的思路。

本章在 KITTI 数据集上, 采用与 4.5 节一致的实验环境重新进行训练并经过关键特征蒸馏, 实验结果如表 4-3 所示, 在对学生模型的骨干网络进行扩容后 FastPillarNet² 模型, 其在车辆检测任务上取得了进一步提升, 尤其是在中等和困难样本上的检测精度有所改善, 甚至略微超越了教师模型。同时, 在行人和自行车类别的检测精度上, 尽管个别情况下略有下降, 但整体仍然保持在较高水平。并且, 骨干网络扩容虽然使得其推理时间增加了 1.3ms, 但推理速度仍然比原始的 VoxelNeXt 快 6.6ms, 提速率达 15.42%。

这一结果表明, 适当扩展骨干网络的容量能够提升学生模型的学习能力, 使其更充分地吸收来自教师模型的几何形状和高度信息。同时也验证了本章的想法, 通过知识蒸馏, 基于柱状体编码结构的网络能够从基于体素编码结构的网络学习丰富的几何形状和高度信息。

表 4-3 KITTI 验证集增强学生模型蒸馏 3D 检测 AP_{R40} 指标对比

模型	车辆 (IOU=0.7)			行人 (IOU=0.5)			自行车 (IOU=0.5)		
	简单	中等	困难	简单	中等	困难	简单	中等	困难
VoxelNeXt	88.70	79.96	77.50	57.39	53.69	49.66	90.46	68.91	64.85
FastPillarNet	86.66	77.79	75.40	55.55	52.43	48.73	91.37	68.14	63.87
FastPillarNet ¹	88.14	79.22	77.26	58.57	53.88	49.91	86.60	68.33	65.71
FastPillarNet ²	87.98	80.23	78.02	57.32	53.66	49.55	90.17	67.67	64.00

VoxelNeXt 为教师模型, 推理时间为 42.8ms

FastPillarNet 为学生模型, 推理时间为 34.9ms

FastPillarNet¹ 使用了关键特征对齐蒸馏

FastPillarNet² 表示骨干网络扩容后的模型并且经过关键特征对齐蒸馏, 推理时间为 36.2ms

4.8 本章小结

本章重点探讨了异构知识蒸馏优化方法, 以进一步提升 FastPillarNet 的检测精度。在与 VoxelNeXt 的比较中, 尽管 FastPillarNet 在推理速度上取得了显著优势, 但在检测精度, 尤其是高度信息建模方面仍存在不足。为了解决这一问题, 本章提出了基于热图的关键特征对齐蒸馏方法, 通过对关键区域特征进行对齐蒸馏, 避免冗余信息干扰, 显著提高了知识传递的有效性。实验结果表明, 这一创新蒸馏方法使学生模型的精度接近教师模型, 且推理速度提高了 18.45%。此外, 通过适当增加骨干网络的容量, 学生模型在检测精度上基本与教师模型保持一致, 并在中等和困难样本上略有超越, 验证了基于柱状体编码的模型在精度上能够与基于体素编码的模型相匹敌, 证明了提出的异构知识蒸馏方法有效弥补了柱状体编码模型在高度维度建模上的不足。

第五章 基于 ROS 和 RViz 的 3D 目标检测可视化系统设计

自动驾驶感知系统需要高效的可视化工具，以直观展示车辆感知到的环境信息。本章设计了一个基于 ROS 和 RViz 的 3D 目标检测可视化系统，使用 KITTI 数据集进行仿真，旨在增强 3D 目标检测结果的可解释性和直观性。系统可同时显示图像序列与点云序列，并根据模型检测结果在点云中标注 3D 检测框，并通过坐标转换计算其在图像上的 2D 投影框。此外，系统还支持绘制车辆轨迹和目标轨迹，并计算自身车辆与检测目标的距离，在点云中用连线标注距离信息。本章详细介绍该可视化系统的设计方案与实现过程。

5.1 ROS 系统架构及其可视化工具 RViz

ROS (Robot Operating System) 是一个分布式计算框架，旨在为机器人系统提供模块化、可扩展的通信机制。如图5-1所示，其系统架构主要由主控管理节点 (Master)、节点 (Node)、话题 (Topic)、服务 (Service) 和消息 (Message) 等核心组件组成。主控管理节点负责节点的注册、命名解析和通信调度，当一个节点启动时，它需要向主控管理节点注册自己，并声明其发布或订阅的话题，从而建立数据流通道。在这一架构下，节点作为 ROS 的基本执行单元，每个节点通常负责某一独立功能，并通过话题或服务进行数据交互。




图 5-1 ROS 架构图

话题采用发布-订阅（Publish-Subscribe）机制实现数据流传输，节点可以选择发布或订阅特定话题，这种机制适用于高频率、连续的数据流，如传感器数据、点云信息、相机图像等。在 3D 目标检测的可视化应用中，LiDAR 点云数据、相机图像以及目标检测的结果都可以通过话题进行传输，以确保不同功能模块的数据同步。服务采用请求-响应机制，适用于低频率的指令式交互，例如请求某个传感器状态或执行一次性计算。此外，消息作为 ROS 中的标准化数据结构，定义了话题和服务传输的信息格式，例如 `sensor_msgs/PointCloud2`（点云数据）和 `sensor_msgs/Image`（图像数据），用户也可以根据需求自定义消息格式。通过这些组件的协同工作，ROS 提供了一种高效、灵活的通信方式，使得 3D 目标检测的可视化系统能够在分布式环境下稳定运行。

在 ROS 生态系统中，RViz（ROS Visualization Tool）是其主要的三维可视化工具，广泛用于显示点云、图像、坐标变换和目标检测结果。RViz 提供了直观的 3D 交互界面，能够渲染和调整不同传感器的数据，可视化 LiDAR 采集的点云信息、相机捕获的图像，以及模型预测的 3D 检测框。其核心功能包括支持多种传感器数据的可视化、提供交互式 3D 视图、管理坐标变换（TF）以及提供标注工具（Marker）用于绘制检测框、运动轨迹和距离标注。在本研究的 3D 目标检测可视化系统中，RViz 的主要作用在于同步显示 LiDAR 点云与相机图像，并利用 TF 进行坐标变换，从而将 3D 目标检测结果正确地投影到图像上。此外，RViz 还可用于绘制车辆及其他目标的运动轨迹，并计算自车与目标物体之间的距离，以便在可视化界面中直观呈现交通环境。综上，ROS 提供了高效的数据管理与通信机制，而 RViz 作为可视化工具，为 3D 目标检测结果的呈现与分析提供了重要支持。

5.2 数据准备与转换

为了实现基于 ROS 和 RViz 的 3D 目标检测可视化系统，需要准备并转换 KITTI 数据集中的相关数据，以确保能够在 ROS 环境中顺利处理和可视化。具体而言，本节将详细介绍所需数据及其转换过程，以便在 ROS 系统中进行有效的读取和展示。

1. KITTI 数据集准备

本章使用 KITTI 数据集进行可视化实验，主要使用以下几部分数据：

(1) 点云数据：这些数据通过激光雷达采集，提供了每个点的三维空间坐标及强度信息。点云数据以 .bin 格式存储，每一帧包含成千上万的点。点云数据将作为 3D 目标检测模型的输入数据，且在 RViz 中进行可视化。

(2) 图像数据：KITTI 数据集提供了与点云数据同步采集的图像数据，分别为

左、右两个相机视角的图像。图像数据用于与点云数据结合，通过坐标转换将 3D 目标检测框投影到图像中，便于在 RViz 中展示。

(3) 标定信息：标定信息包括相机的内参（焦距、主点等）和相机与激光雷达之间的外参（旋转矩阵和偏移量）。这些参数用于将激光雷达坐标系下的点云数据转换到相机坐标系，从而使得检测结果可以在图像中进行投影。

2. 数据转换为 ROS 可读取格式

为了在 ROS 中处理和可视化 KITTI 数据集中的点云和图像数据，本章使用 kitti2bag 工具将 KITTI 数据转换为 ROS 的 rosbag 格式。rosbag 是一种 ROS 专用的数据存储格式，可以方便地记录和播放消息。具体的转换步骤如下：

(1) 点云数据转换：点云数据将被转换为 ROS 中的 sensor_msgs/PointCloud2 消息类型。该消息类型包含了点云的空间坐标和强度信息，适用于在 ROS 中进行后续处理和可视化。kitti2bag 工具会自动将点云数据从 KITTI 的 .bin 格式转换为 ROS 支持的 PointCloud2 格式，确保数据能在 ROS 环境中正确读取和使用。

(2) 图像数据转换：图像数据将转换为 ROS 中的 sensor_msgs/Image 消息类型。通过 kitti2bag 工具，左、右相机的图像数据将被封装为 ROS 消息，传递给 ROS 系统进行处理和显示。图像数据的格式将根据 KITTI 数据集中的 .png 或 .jpg 文件进行自动转换。

(3) 标定信息转换：标定信息也将被包含在 ROS 的 rosbag 文件中。通过 kitti2bag 工具，KITTI 数据集中的标定文件将被解析，并将相机的内参和外参信息以适当的格式保存在 ROS 中，以便进行点云与图像之间的坐标转换。

通过上述的数据准备和转换过程，KITTI 数据集中的点云和图像数据将能够在 ROS 系统中正确加载，转换后的数据在 RViz 中的可视化效果如图 5-2 所示。




图 5-2 KITTI 数据可视化效果图

5.3 图像序列和点云序列可视化

为了在 ROS 和 RViz 中实现可视化, 需要显示同步采集的图像和点云序列, 并在点云中添加相应的摄像头视角以及一个车辆模型。这一过程需要通过 ROS 的消息通信机制将 KITTI 数据集中的图像和点云数据传输到 RViz, 并在点云可视化界面中标注摄像头视角和车辆模型。

1. 显示图像和点云序列

在 RViz 中, 本章通过以下步骤加载并显示图像和点云序列:

(1) 图像显示: 通过 Image 类型的显示器, 将图像序列显示在 RViz 界面中。每一帧图像数据通过 ROS 消息发布, RViz 实时更新图像。

(2) 点云显示: 通过 PointCloud2 类型的显示器, 将点云数据加载到 RViz 中。点云数据包含每个激光雷达采集的三维坐标, 显示器将这些数据转化为三维点云并呈现出来。

因为 KITTI 数据集中的图像和点云数据是同步采集的, 所以每一帧的图像数据与对应的点云数据在时间戳上是一致的。在 ROS 中, 本章通过时间同步机制将这两个数据流进行配对, 确保它们在 RViz 中正确显示。

2. 绘制相机视角

KITTI 数据集中, 摄像头的视角较窄, 因此需要在点云显示中标出摄像头的视角范围。本章通过绘制两个线段来实现, 这两个线段代表摄像头的视场边界。为了在 RViz 中显示这些线段, 可以使用 ROS 中的 Marker 消息类型, 该类型支持绘制线条和其他几何图形。

本章根据 KITTI 数据集中相机的内参 (包括焦距和视场角等), 计算出摄像头的视角范围, 并在点云数据中绘制出表示视场范围的两条线段。这两条线段在点云中显示, 标示了摄像头的视场边界, 帮助观察者理解点云数据与摄像头视角之间的关系。

3. 添加车辆模型

由于 KITTI 数据集中的点云数据通常会在车辆的位置形成空白区域, 因此需要在点云中添加一个车辆模型, 以填补这一空白并使可视化效果更加完整。为了实现这一点, 可以通过 ROS 中的 Marker 消息类型, 加载一个简单的 3D 车辆模型, 并将其添加到点云显示中。

车辆模型可以通过标准的 3D 模型格式加载到 RViz 中。本章通过指定车辆模型的相对位置、旋转角度和缩放因子, 将车辆模型准确地放置在点云数据的合适位置, 也就是是激光雷达数据中的空白区域。这样, 不仅增强了可视化效果, 也帮助更好地理解点云数据的空间布局。

4. 最终效果

通过上述步骤，本章在 ROS 和 RViz 中成功地展示了 KITTI 数据集中的图像序列和点云序列，同时在点云中绘制了相机视角线段并添加了车辆模型。图像与点云数据同步显示，帮助用户更好地理解 3D 目标检测模型的工作原理和可视化结果。

最终效果如图5-3所示，可以看到点云中绘制的相机视角线段和车辆模型，这些可视化元素有效地帮助用户了解数据的空间关系和模型的检测效果。




图 5-3 图像和点云可视化效果图

5.4 3D 目标检测框与 2D 目标检测框的可视化

为了将训练好的 3D 目标检测模型应用于 ROS 系统并在 RViz 中进行可视化，首先，需要将点云数据传递给该模型进行预测，由于模型接受的输入数据格式为.bin 文件，因此需要将点云数据从 ROS 的 sensor_msgs/PointCloud2 消息格式转换为.bin 格式。通过 ROS 中的转换节点，本章将每一帧的点云数据保存为.bin 文件，并将其输入到训练好的模型中进行预测。模型输出的结果包括每个检测物体的 3D 边界框（位置、尺寸和旋转角度等。随后，将输出结果整理成适合可视化的格式，通过 visualization_msgs/Marker 消息格式发布，以便在 RViz 中展示。

为了在点云数据上可视化 3D 检测框，本章使用 ROS 中的 MarkerArray 消息类型将每个检测框的位置信息（ x, y, z ）和尺寸（长、宽、高）进行封装。通过设置合适的颜色和透明度，用户可以直观地观察到点云中的检测框，这样可以帮助分析目标物体的位置和空间布局。接下来，为了进一步增强可视化效果，并将 3D

检测框与图像中的 2D 检测框关联，本章利用标定信息将 3D 检测框投影到图像上。

具体来说，本章将利用相机标定信息（包括相机内参和外参）将 3D 检测框转换为 2D 检测框。通过相机的内外参，可以将激光雷达坐标系下的 3D 坐标点投影到图像坐标系中。假设 3D 点的坐标为 $P_{3D} = [X, Y, Z, 1]^T$ ，通过投影矩阵 $P = [K|T]$ （其中 K 是相机内参矩阵， T 是相机外参矩阵），可以计算得到相应的 2D 坐标 $P_{2D} = [x, y, 1]^T$ ，即：

$$P_{2D} = K \cdot [R|T] \cdot P_{3D} \quad (5-1)$$

其中， R 为旋转矩阵， T 为平移矩阵， K 为相机内参矩阵， P_{3D} 为 3D 点在激光雷达坐标系中的坐标， P_{2D} 为映射到图像坐标系中的 2D 坐标。

在得到 2D 坐标后，本章根据投影结果计算 2D 边界框的位置，并使用 ROS 消息格式在 RViz 中绘制 2D 检测框。这样，通过结合 3D 检测框和 2D 检测框，用户可以在 RViz 中同时观察到点云数据上的物体以及相应的 2D 边界框，进一步提高了可视化效果。

如图 5-4 所示，通过以上步骤，本章在 ROS 系统中实现 3D 目标检测框的生成和可视化，并将 3D 检测框投影到图像中生成 2D 检测框。这种多维度的可视化方式能够直观地展示检测结果，并为自动驾驶系统提供有力的支持。




图 5-4 图像和点云可视化效果图

5.5 车辆与目标物运动轨迹及距离可视化

为了实现绘制自身车辆和识别出的物体的运动轨迹图，并计算车辆与其他目标物之间的距离并通过连线显示，本章将依赖 KITTI 数据集提供的 GPS 信息。通过 GPS 数据，能够精确获取车辆在全球坐标系中的位置，并根据这些位置绘制出车辆的运动轨迹。同时，通过点云数据中的 3D 检测框信息，可以计算出车辆与其他识别物体之间的距离，并在可视化界面中绘制连线显示这些距离。

GPS 数据包含车辆在每一帧的经度、纬度和高度信息，以及车辆的朝向和速度。为了展示车辆的运动轨迹，需要将这些 GPS 坐标转换为 ROS 支持的坐标系，并通过 ROS 发布消息进行可视化。本章将使用 ROS 的 `geometry_msgs/Pose` 消息类型来表示车辆的位置，并在 RViz 中绘制车辆的轨迹。

通过对每一帧的 GPS 信息进行处理，可以将每个时间点的车辆位置标记在 RViz 界面上，形成一条表示车辆路径的连续曲线。由于 GPS 坐标系通常是全球坐标系（如 WGS84 坐标系），在 ROS 中，可以选择使用与其兼容的局部坐标系进行展示，便于后续计算和可视化。

对于目标物体（如其他车辆或行人）的识别，本研究依赖训练好的 3D 目标检测模型来检测目标物体并获取其 3D 边界框。每一帧的目标物体检测结果包括物体的 3D 边界框的位置和尺寸。通过计算检测框中心的位置，可以将目标物体与车辆之间的距离计算出来。车辆与目标物体之间的距离通过计算两者坐标之间的欧氏距离来完成。

在 ROS 中，车辆的运动轨迹可以通过发布 `geometry_msgs/Pose` 消息来实现，将车辆位置通过 rviz 实时绘制成轨迹。此外，目标物体的 3D 边界框可以通过 ROS 的 `visualization_msgs/Marker` 类型来表示。在可视化界面中，检测到的物体通过 3D 边界框显示，且车辆和物体之间的连线可以通过在 ROS 中发布 `visualization_msgs/Marker` 来实现。

每一帧的车辆位置和目标物体之间的距离将通过连线显示在 RViz 中，连线的长度表示车辆与目标物体之间的距离。为了进一步提高可视化的清晰度，距离值也可以通过文本标注在连线上显示。

图5-5展示了最终的可视化效果，车辆和目标的运动轨迹表现为一条随时间推移而逐渐延伸的曲线，每个目标物体的检测框将显示为三维边界框，目标物体与车辆之间的距离将通过连线显示，连线旁标注了实际的空间距离。



图 5-5 车辆与目标物运动轨迹及距离可视化效果图

5.6 本章小结

本章实现了基于 ROS 和 RViz 的自动驾驶可视化系统，涵盖了多个关键功能。首先，通过同步显示 KITTI 数据集中的视频序列和点云序列，并在点云中绘制摄像头视角和车辆模型，从而增强了点云数据的可视化效果。其次，将 3D 目标检测模型的检测结果投影到图像中，展示了同时在点云和图像中可视化的 3D 检测框与 2D 检测框。最后，通过计算车辆与其他目标物体之间的距离，并在可视化界面上通过连线展示这些距离，为目标物体的空间关系提供了直观的展示。这些功能为自动驾驶目标检测的评估、调试和优化提供了有力的支持和直观的数据展示手段。

第六章 全文总结与展望

6.1 全文总结

本研究围绕面向自动驾驶的轻量化目标检测算法展开，重点探讨了如何在提高推理效率的同时保持检测精度。本文的研究工作主要包括轻量化模型设计和异构知识蒸馏优化两个方面，分别针对 3D 目标检测网络的计算效率和精度瓶颈提出了创新性方案。

在轻量化建模方面，本文对当前高效的 3D 目标检测网络 VoxelNeXt 进行了进一步优化。VoxelNeXt 采用全稀疏卷积实现高效 3D 目标检测，其对传统检测头使用了稀疏卷积优化并使用最大池化代替了传统的非极大值抑制，在保证精度的同时提高了推理效率。然而，其仍然采用体素编码器进行点云特征提取，并在骨干网络中使用 3D 稀疏卷积进行特征建模，计算效率仍有提升的空间，并且，其在对检测头使用稀疏卷积优化时，也未能充分发挥稀疏卷积的优势。

针对这一问题，本文提出了一种轻量化的 3D 目标检测网络 FastPillarNet，并提出一种创新的异构知识蒸馏进一步提升性能。

1. 模型结构的轻量化设计

(1) 编码器轻量化：将体素编码器替换为柱状体编码器，减少了 3D 空间上的计算量，使网络在输入阶段即实现降维优化。

(2) 骨干网络轻量化：将原有的 3D 稀疏卷积骨干网络替换为 2D 稀疏卷积，利用 BEV 表示进行特征建模，大幅减少计算量，同时仍能保持有效的空间信息传递。

(3) 轻量化优化策略：在 FastPillarNet 设计的基础上，本文进一步引入了三种轻量化策略，以减少无效计算并提升推理速度：

- 地面点云过滤：通过分析自动驾驶场景的特性，过滤掉无关的地面点云，减少输入数据量。
- 基于高度的柱状体点云稀疏采样：在柱状体内部，根据点云高度信息进行稀疏采样，降低冗余数据，同时保留关键信息。
- 检测头的关键特征筛选：基于热图筛选关键特征，仅对重要区域进行检测，提高计算效率。

实验结果表明，FastPillarNet 在保持较高检测精度的同时，实现了显著的推理速度提升。结构上的优化使得 FastPillarNet 相较于 VoxelNeXt 提升了 9.81% 的推理速度，而三种轻量化优化策略联合使用，使得 FastPillarNet 进一步获得 12.44% 的

提速。

2. 异构知识蒸馏优化

尽管 FastPillarNet 在推理速度上获得了显著提升，但与 VoxelNeXt 相比，其检测精度仍有一定差距，特别是在高度信息建模方面表现较弱。分析发现，这主要源于柱状体编码结构在 z 轴（高度方向）上的建模能力较弱。与体素编码结构不同，柱状体编码结构在高度维度上缺乏显式的建模，因此，在检测较高物体时，精度有所下降。

为了弥补柱状体结构结构的精度损失，本文首先尝试了朴素的特征蒸馏和 ROI 特征蒸馏，但发现效果仍然有限。因此，本文进一步提出了一种基于热图的关键特征对齐蒸馏方法，其核心思想是仅对关键区域的特征进行对齐蒸馏，避免冗余信息的干扰，提高知识传递的有效性。实验结果表明，这种创新的蒸馏方法使得学生模型的精度获得了显著的提升，非常接近于教师模型的表现，并且实现了相对于教师模型 18.45% 的提速率。

此外，为了进一步验证学生模型的潜力，本文适当增加了骨干网络的容量，使得每个 ResNet 级联模块的卷积层数从 2 层增加到 3 层，同时仍然保持较低的计算成本，相比原始的 VoxelNeXt 仍有 15.42% 的提速。实验表明，骨干网络扩容后的学生模型的检测精度达到与教师模型相当的水平，甚至在车辆类型的中等和困难样本上略微超越了教师模型，这有力的验证了本文的猜想，即基于柱状体编码的模型也有能力达到和基于体素编码的模型一样的检测精度，只是其缺乏对点云高度维度的显式建模，而本文提出的异构知识蒸馏方法能够很好的弥补这一点。

6.2 后续工作展望

本研究在轻量化 3D 目标检测方向取得了一定进展，但仍有许多值得进一步探索的研究方向。

首先，当前自动驾驶系统往往配备多传感器融合方案，包括激光雷达和摄像头。目前已有大量研究工作关注点云-图像融合的 3D 目标检测，结合点云的空间几何信息与图像的纹理特征可以进一步提升检测精度。然而，点云和图像的特征存在模态差异，融合方式的设计对计算开销和检测性能有较大影响。因此，如何将本文提出的基于点云的轻量化方法迁移到点云-图像融合的目标检测任务中，是一个值得进一步研究的方向。此外，如何在多模态融合网络中高效应用知识蒸馏技术，使轻量化模型能够充分利用图像和点云的互补信息，也是一个重要的研究课题。

其次，本文提出的点云目标检测网络是单帧检测模型，即仅利用单个时刻的

点云数据进行目标检测。然而，在自动驾驶场景中，车辆行驶过程中的相邻帧点云之间具有较高的相似性，这为利用时序信息提升检测性能提供了可能性。未来的研究可以探索基于时序的轻量化 3D 目标检测，例如利用前一帧的检测结果来辅助当前帧的预测，从而减少计算量，提高检测精度。此外，结合运动补偿和时序特征提取的方法，有望进一步增强模型对动态场景的适应能力，实现更高效、稳定的目标检测。

最后，轻量化 3D 目标检测方法在嵌入式计算设备上的部署仍面临挑战。未来研究可以探索如何进一步优化模型的计算图、利用低比特量化或神经架构搜索等方法，以进一步提升模型在资源受限环境下的运行效率。此外，研究高效的分布式计算方案，利用多传感器、多计算单元协同处理点云数据，也将是推动轻量化 3D 目标检测落地应用的重要方向。

致 谢

首先，我要向我的导师表达最诚挚的感谢。导师在我研究过程中给予了悉心指导和宝贵建议，不仅在学术上提供了重要的启发，也在论文撰写和科研思路给予了极大的帮助，使我得以顺利完成本论文。

同时，我要感谢实验室的同学们，在科研过程中给予了许多帮助和鼓励。与大家的交流和讨论让我受益匪浅，也让我在研究的道路上不断进步。

此外，我还要感谢我的家人和朋友，在我攻读研究生期间给予我无私的支持和鼓励。他们的理解和陪伴让我能够保持动力，克服科研中的各种挑战。

参考文献

- [1] Thrun S, Montemerlo M, Dahlkamp H, et al. Stanley: The robot that won the darpa grand challenge[J]. Journal of field Robotics, 2006, 23(9): 661-692.
- [2] Thrun S. Toward robotic cars[J]. Communications of the ACM, 2010, 53(4): 99-106.
- [3] Dikmen M, Burns C M. Autonomous driving in the real world: Experiences with tesla autopilot and summon[C]. Proceedings of the 8th international conference on automotive user interfaces and interactive vehicular applications, 2016: 225-228.
- [4] Anderson J M, Nidhi K, Stanley K D, et al. Autonomous vehicle technology: A guide for policymakers[M]. Rand Corporation, 2014.
- [5] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2014: 580-587.
- [6] Girshick R. Fast r-cnn[C]. Proceedings of the IEEE international conference on computer vision, 2015: 1440-1448.
- [7] Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. IEEE transactions on pattern analysis and machine intelligence, 2016, 39(6): 1137-1149.
- [8] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 779-788.
- [9] Redmon J, Farhadi A. Yolo9000: better, faster, stronger[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 7263-7271.
- [10] Redmon J, Farhadi A. Yolov3: An incremental improvement[J]. arXiv preprint arXiv:1804.02767, 2018.
- [11] Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector[C]. Computer Vision—ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part I 14, 2016: 21-37.
- [12] Duan K, Bai S, Xie L, et al. Centernet: Keypoint triplets for object detection[C]. Proceedings of the IEEE/CVF international conference on computer vision, 2019: 6569-6578.

- [13] Lin T Y, Maire M, Belongie S, et al. Microsoft coco: Common objects in context[C]. Computer vision–ECCV 2014: 13th European conference, zurich, Switzerland, September 6-12, 2014, proceedings, part v 13, 2014: 740-755.
- [14] Everingham M, Van Gool L, Williams C K, et al. The pascal visual object classes (voc) challenge[J]. International journal of computer vision, 2010, 88: 303-338.
- [15] Chen X, Kundu K, Zhang Z, et al. Monocular 3d object detection for autonomous driving[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 2147-2156.
- [16] He T, Soatto S. Mono3d++: Monocular 3d vehicle detection with two-scale 3d hypotheses and task priors[C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2019: 8409-8416.
- [17] Kundu A, Li Y, Rehg J M. 3d-rcnn: Instance-level 3d object reconstruction via render-and-compare[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 3559-3568.
- [18] Mousavian A, Anguelov D, Flynn J, et al. 3d bounding box estimation using deep learning and geometry[C]. Proceedings of the IEEE conference on Computer Vision and Pattern Recognition, 2017: 7074-7082.
- [19] Liu Z, Wu Z, Tóth R. Smoke: Single-stage monocular 3d object detection via keypoint estimation[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops, 2020: 996-997.
- [20] Peng L, Wu X, Yang Z, et al. Did-m3d: Decoupling instance depth for monocular 3d object detection[C]. European Conference on Computer Vision, 2022: 71-88.
- [21] Huang K C, Wu T H, Su H T, et al. Monodtr: Monocular 3d object detection with depth-aware transformer[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2022: 4012-4021.
- [22] Zhang R, Qiu H, Wang T, et al. Monodetr: Depth-guided transformer for monocular 3d object detection[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023: 9155-9166.
- [23] Ma X, Zhang Y, Xu D, et al. Delving into localization errors for monocular 3d object detection[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 4721-4730.

-
- [24] Liu X, Xue N, Wu T. Learning auxiliary monocular contexts helps monocular 3d object detection[C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2022: 1810-1818.
 - [25] Li P, Chen X, Shen S. Stereo r-cnn based 3d object detection for autonomous driving[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 7644-7652.
 - [26] Qin Z, Wang J, Lu Y. Triangulation learning network: from monocular to stereo 3d object detection[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019: 7615-7623.
 - [27] Sun J, Chen L, Xie Y, et al. Disp r-cnn: Stereo 3d object detection via shape prior guided instance disparity estimation[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2020: 10548-10557.
 - [28] Xu Z, Zhang W, Ye X, et al. Zoomnet: Part-aware adaptive zooming neural network for 3d object detection[C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020: 12557-12564.
 - [29] Chen Y, Liu S, Shen X, et al. Dsgn: Deep stereo geometry network for 3d object detection[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2020: 12536-12545.
 - [30] Chen Y, Huang S, Liu S, et al. Dsgn++: Exploiting visual-spatial relation for stereo-based 3d detectors[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 45(4): 4416-4429.
 - [31] Wang Y, Chao W L, Garg D, et al. Pseudo-lidar from visual depth estimation: Bridging the gap in 3d object detection for autonomous driving[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019: 8445-8453.
 - [32] You Y, Wang Y, Chao W L, et al. Pseudo-lidar++: Accurate depth for 3d object detection in autonomous driving[J]. arXiv preprint arXiv:1906.06310, 2019.
 - [33] Li B, Zhang T, Xia T. Vehicle detection from 3d lidar using fully convolutional network[J]. arXiv preprint arXiv:1608.07916, 2016.
 - [34] Beltrán J, Guindel C, Moreno F M, et al. Birdnet: a 3d object detection framework from lidar information[C]. 2018 21st International Conference on Intelligent Transportation Systems (ITSC), 2018: 3517-3523.

- [35] Barrera A, Guindel C, Beltrán J, et al. Birdnet+: End-to-end 3d object detection in lidar bird's eye view[C]. 2020 IEEE 23rd International Conference on Intelligent Transportation Systems (ITSC), 2020: 1-6.
- [36] Yang B, Luo W, Urtasun R. Pixor: Real-time 3d object detection from point clouds[C]. Proceedings of the IEEE conference on Computer Vision and Pattern Recognition, 2018: 7652-7660.
- [37] Zhou Y, Sun P, Zhang Y, et al. End-to-end multi-view fusion for 3d object detection in lidar point clouds[C]. Conference on Robot Learning, 2020: 923-932.
- [38] Meyer G P, Laddha A, Kee E, et al. Lasernet: An efficient probabilistic 3d object detector for autonomous driving[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019: 12677-12686.
- [39] Zhou Y, Tuzel O. Voxelnet: End-to-end learning for point cloud based 3d object detection[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 4490-4499.
- [40] He C, Zeng H, Huang J, et al. Structure aware single-stage 3d object detection from point cloud[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2020: 11873-11882.
- [41] Deng J, Shi S, Li P, et al. Voxel r-cnn: Towards high performance voxel-based 3d object detection[C]. Proceedings of the AAAI conference on artificial intelligence, 2021: 1201-1209.
- [42] Yan Y, Mao Y, Li B. Second: Sparsely embedded convolutional detection[J]. Sensors, 2018, 18(10): 3337.
- [43] Ye M, Xu S, Cao T. Hvnet: Hybrid voxel network for lidar based 3d object detection[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2020: 1631-1640.
- [44] Wu H, Wen C, Li W, et al. Transformation-equivariant 3d object detection for autonomous driving[C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2023: 2795-2802.
- [45] Yang H, Wang W, Chen M, et al. Pvt-ssd: Single-stage 3d object detector with point-voxel transformer[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023: 13476-13487.
- [46] Chen Y, Liu J, Zhang X, et al. Voxelnext: Fully sparse voxelnet for 3d object detection and tracking[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023: 21674-21683.

-
- [47] Shi S, Guo C, Jiang L, et al. Pv-rcnn: Point-voxel feature set abstraction for 3d object detection[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2020: 10529-10538.
- [48] Shi S, Jiang L, Deng J, et al. Pv-rcnn++: Point-voxel feature set abstraction with local vector representation for 3d object detection[J]. International Journal of Computer Vision, 2023, 131(2): 531-551.
- [49] Qi C R, Su H, Mo K, et al. Pointnet: Deep learning on point sets for 3d classification and segmentation[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 652-660.
- [50] Qi C R, Yi L, Su H, et al. Pointnet++: Deep hierarchical feature learning on point sets in a metric space[J]. Advances in neural information processing systems, 2017, 30.
- [51] Shi S, Wang X, Li H. Pointrcnn: 3d object proposal generation and detection from point cloud[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019: 770-779.
- [52] Yang Z, Sun Y, Liu S, et al. 3dssd: Point-based 3d single stage object detector[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2020: 11040-11048.
- [53] Zhang Y, Hu Q, Xu G, et al. Not all points are equal: Learning highly efficient point-based detectors for 3d lidar point clouds[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2022: 18953-18962.
- [54] Pan X, Xia Z, Song S, et al. 3d object detection with pointformer[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2021: 7463-7472.
- [55] Lang A H, Vora S, Caesar H, et al. Pointpillars: Fast encoders for object detection from point clouds[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019: 12697-12705.
- [56] Wang Y, Fathi A, Kundu A, et al. Pillar-based object detection for autonomous driving[C]. Computer Vision—ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XXII 16, 2020: 18-34.
- [57] Fan L, Pang Z, Zhang T, et al. Embracing single stride 3d object detector with sparse transformer[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2022: 8458-8468.
- [58] Qi C R, Liu W, Wu C, et al. Frustum pointnets for 3d object detection from rgb-d data[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 918-927.

- [59] Wang Z, Jia K. Frustum convnet: Sliding frustums to aggregate local point-wise features for amodal 3d object detection[C]. 2019 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2019: 1742-1749.
- [60] Paigwar A, Sierra-Gonzalez D, Erkent Ö, et al. Frustum-pointpillars: A multi-stage approach for 3d object detection using rgb camera and lidar[C]. Proceedings of the IEEE/CVF international conference on computer vision, 2021: 2926-2933.
- [61] Chen X, Ma H, Wan J, et al. Multi-view 3d object detection network for autonomous driving[C]. Proceedings of the IEEE conference on Computer Vision and Pattern Recognition, 2017: 1907-1915.
- [62] Xu D, Anguelov D, Jain A. Pointfusion: Deep sensor fusion for 3d bounding box estimation[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 244-253.
- [63] Huang T, Liu Z, Chen X, et al. Epnet: Enhancing point features with image semantics for 3d object detection[C]. Computer vision—ECCV 2020: 16th European conference, Glasgow, UK, August 23–28, 2020, proceedings, part XV 16, 2020: 35-52.
- [64] Ku J, Mozifian M, Lee J, et al. Joint 3d proposal generation and object detection from view aggregation[C]. 2018 IEEE/RSJ international conference on intelligent robots and systems (IROS), 2018: 1-8.
- [65] Pang S, Morris D, Radha H. Clocs: Camera-lidar object candidates fusion for 3d object detection[C]. 2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2020: 10386-10393.
- [66] Pang S, Morris D, Radha H. Fast-clocs: Fast camera-lidar object candidates fusion for 3d object detection[C]. Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision, 2022: 187-196.
- [67] Mao J, Shi S, Wang X, et al. 3d object detection for autonomous driving: A comprehensive survey[J]. International Journal of Computer Vision, 2023, 131(8): 1909-1963.
- [68] Law H, Deng J. Cornernet: Detecting objects as paired keypoints[C]. Proceedings of the European conference on computer vision (ECCV), 2018: 734-750.
- [69] Yin T, Zhou X, Krahenbuhl P. Center-based 3d object detection and tracking[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2021: 11784-11793.
- [70] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network[J]. arXiv preprint arXiv:1503.02531, 2015.

- [71] Gou J, Yu B, Maybank S J, et al. Knowledge distillation: A survey[J]. International Journal of Computer Vision, 2021, 129(6): 1789-1819.
- [72] Mao W, Wang T, Zhang D, et al. Pillarnest: Embracing backbone scaling and pretraining for pillar-based 3d object detection[J]. IEEE Transactions on Intelligent Vehicles, 2024.